جلسه‌ی ۱

۱

NumPy: پایه‌ی محاسبات عددی

آرایه، برداری‌سازی و پخش؛ زبان مشترک همه‌ی ابزارهای علم داده

ترم دوم: علم داده | کیوان محمودی

چرخه‌ی کار در علم داده

۱ **طرح سؤال**
دقیقاً چه چیزی را می‌خواهیم بفهمیم؟

۲ **جمع‌آوری**
فایل، پایگاه داده، API

۳ **پاک‌سازی**
گمشده، تکرار، خطا

۴ **تحلیل اکتشافی**
آمار توصیفی و نمودار

۵ **آزمون و مدل**
پاسخ کمّی به سؤال

۶ **ارائه**
گزارش برای تصمیم‌گیرنده

در این ترم ابزار همه‌ی مراحل را یاد می‌گیریم؛ مدل‌سازی یادگیری ماشین موضوع ترم بعد است.

چرا NumPy؟

۲۵×

سریع‌تر از حلقه‌ی پایتون برای جمع مربع یک میلیون عدد

۱

نوع داده برای همه‌ی عناصر یک آرایه

C

عملیات با کد کامپایل‌شده اجرا می‌شود

لیست پایتون هر نوع شیئی را نگه می‌دارد و همین آن را کند می‌کند. آرایه‌ی NumPy هم‌نوع و پیوسته در حافظه است. Pandas، scikit-learn، Matplotlib و PyTorch همه روی آن ساخته شده‌اند.

ساختن آرایه و ویژگی‌های آن

```
import numpy as np

a = np.array([3, 1, 4, 1, 5, 9])
m = np.arange(1, 13).reshape(3, 4)

m.ndim, m.shape, m.dtype
# (2, (3, 4), dtype('int64'))

np.zeros(4)          # [0. 0. 0. 0.]
np.linspace(0, 1, 5) # [0. .25 .5 .75 1.]
np.array([1, "2"])   # dtype <U21 !
```

- ndim: تعداد ابعاد
- shape: اندازه در هر بعد
- dtype: نوع عناصر؛ مخلوط کردن نوع‌ها همه را به عمومی‌ترین نوع تبدیل می‌کند
- اگر ستون عددی ناگهان متنی شد، یک مقدار غیرعددی در آن هست

اندیس‌گذاری بولی: فیلتر کردن داده

```
temps = np.array([12.5, 18, 25.3, 31.2,
                  8.4, 22.1, 35.6])

mask = temps > 20
temps[mask]
# [25.3 31.2 22.1 35.6]

temps[(temps >= 15) & (temps <= 30)]
mask.mean()          # 0.57

np.where(temps > 20, "hot", "cold")
```

- مقایسه روی آرایه، آرایه‌ای از True/False می‌دهد
- با & (و)، | (یا) و ~ (نقیض) شرط‌ها را ترکیب کنید؛ هر شرط داخل پرانتز
- mask.sum() تعداد و mask.mean() نسبت را می‌دهد
- برش (slice) نما است نه کپی؛ برای نسخه‌ی مستقل copy()

پخش (Broadcasting)

۱ قاعده

شکل‌ها از راست به چپ مقایسه می‌شوند. دو بُعد سازگارند اگر برابر باشند یا یکی‌شان ۱ باشد.

۲ (4 ,3) با (4,)

سازگار: آرایه‌ی کوچک روی هر سطر پخش می‌شود. مثال: کم کردن میانگین هر ستون.

۳ (4 ,3) با (1 ,3)

سازگار: پخش روی ستون‌ها. با keepdims=True شکل ستونی را نگه دارید.

۴ (4 ,3) با (3,)

ناسازگار: خطا. NumPy حدس نمی‌زند منظور شما سطر بوده یا ستون.

تجمیع روی محورها

- axis=0: در امتداد سطرها، یک نتیجه برای هر ستون
- axis=1: در امتداد ستون‌ها، یک نتیجه برای هر سطر
- محوری که مشخص می‌کنید، حذف می‌شود
- std، cumsum، argmax و ... همه پارامتر axis دارند

```
sales = np.array([[12, 15,  9, 20],
                  [30, 28, 35, 40],
                  [ 7,  6,  8,  5]])

sales.sum(axis=0)     # per quarter
# [49 49 52 65]
sales.sum(axis=1)     # per branch
# [ 56 133  26]

z = (sales - sales.mean(axis=0)) / sales.std(axis=0)
```

اعداد تصادفی تکرارپذیر

- مولد را با default_rng(seed) بسازید
- با seed یکسان، هر کسی همان اعداد را می‌گیرد؛ برای کار علمی ضروری است
- integers، normal، choice و shuffle برای شبیه‌سازی و نمونه‌گیری

```
rng = np.random.default_rng(seed=2026)

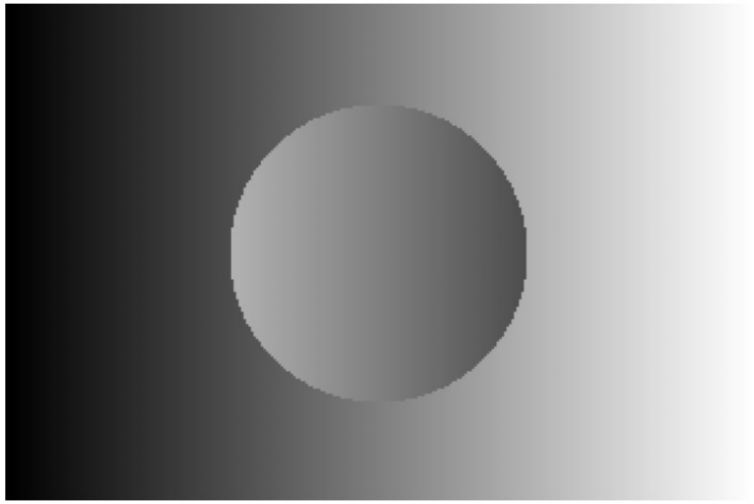
rng.integers(1, 7, size=10)      # dice
rng.normal(loc=170, scale=8, size=4)
rng.choice(["A", "B", "C"], size=6,
           p=[0.5, 0.3, 0.2])
```

تصویر هم یک آرایه است

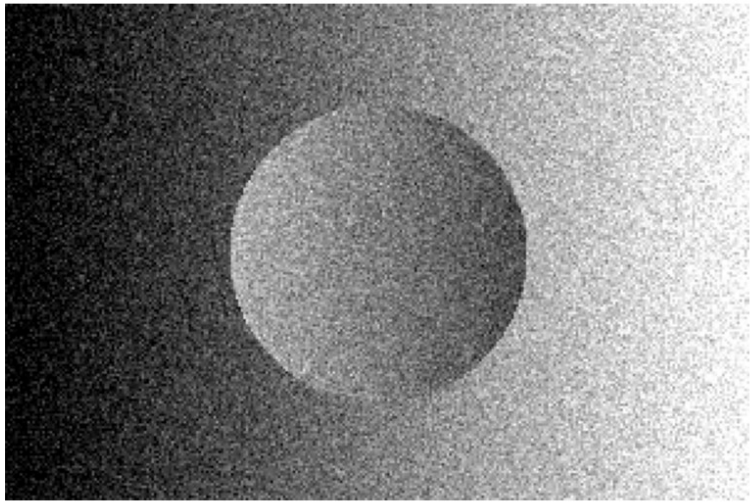
gradient



masked inversion



with noise



تصویر خاکستری ماتریسی از اعداد ۰ تا ۲۵۵ است. با پخش، ماسک بولی و np.clip می‌توان تصویر ساخت و ویرایش کرد.

جمع‌بندی و تمرین

۱ به‌جای حلقه، برداری فکر کنید: عملیات روی کل آرایه

۲ اندیس‌گذاری بولی ابزار اصلی فیلتر کردن داده است

۳ پخش، ترکیب آرایه‌های با شکل متفاوت را بدون حلقه ممکن می‌کند

۴ تمرین: جدول ضرب ۹×۹ را بدون حلقه بسازید

۵ تمرین: احتمال جمع ۷ در پرتاب دو تاس را با ۱۰۰ هزار شبیه‌سازی تخمین بزنید

۶ نوت‌بوک: notebooks/01_numpy_fundamentals.ipynb