جلسه‌ی ۲

۲

مبانی Pandas

کار با داده‌ی جدولی: خواندن، انتخاب، فیلتر و ساختن ستون

ترم دوم: علم داده | کیوان محمودی

دو ساختار اصلی

۱ Series

یک ستون با برچسب (index). مثل یک آرایه‌ی NumPy که هر عنصرش نام دارد: population["Tehran"]

۲ DataFrame

جدولی از چند Series با index مشترک. هر ستون نوع خودش را دارد؛ مثل یک شیت اکسل یا جدول پایگاه داده.

اولین نگاه به داده

دستور	چه چیزی نشان می‌دهد
df.shape	تعداد سطر و ستون
df.head() / df.sample()	چند سطر نمونه
df.info()	نوع هر ستون و تعداد مقادیر غیرگمشده
df.describe()	آمار خلاصه‌ی ستون‌های عددی
df.isna().sum()	تعداد مقادیر گمشده‌ی هر ستون

داده‌ی این جلسه: اندازه‌های بدن ۳۴۴ پنگوئن از سه گونه در سه جزیره (Palmer Penguins).

انتخاب سطر و ستون

۱ [ ]

df["col"] یک Series و df[["a","b"]] یک DataFrame برمی‌گرداند.

۲ loc

بر اساس برچسب. انتهای بازه را شامل می‌شود: df.loc[0:3,["species"]]

۳ iloc

بر اساس موقعیت عددی. مثل پایتون، انتهای بازه را شامل نمی‌شود: df.iloc[0:3,0:4]

فیلتر کردن

- همان اندیس‌گذاری بولی NumPy، این بار روی جدول
- isin برای چند مقدار، between برای بازه
- query شرط را مثل یک عبارت متنی خوانا می‌کند

```
heavy = df[df["body_mass_g"] > 5500]

df[(df["species"] == "Adelie") &
   (df["island"] != "Torgersen")]

df[df["island"].isin(["Biscoe", "Dream"])]
df[df["flipper_length_mm"].between(190, 200)]

df.query("species == 'Gentoo' and "
         "body_mass_g < 4500")
```

یک درس تحلیلی از crosstab

گونه	Biscoe	Dream	Torgersen
Adelie	44	56	52
Chinstrap	0	68	0
Gentoo	124	0	0

Gentoo فقط در Biscoe و Chinstrap فقط در Dream زندگی می‌کند. هر تفاوتی که بین جزیره‌ها ببینیم ممکن است در واقع تفاوت گونه‌ها باشد.

ساختن ستون جدید

- عملیات روی ستون‌ها برداری است
- np.where برای شرط ساده، pd.cut برای بازه‌بندی
- map با دیکشنری برای جایگزینی مقادیر
- apply در واقع حلقه است؛ فقط برای منطق پیچیده

```
df["body_mass_kg"] = df["body_mass_g"] / 1000
df["bill_ratio"] = (df["bill_length_mm"]
                    / df["bill_depth_mm"])

df["mass_band"] = pd.cut(
    df["body_mass_g"],
    bins=[0, 3500, 4500, 5500, np.inf],
    labels=["light", "medium",
            "heavy", "very heavy"])
```

زنجیره‌ی متدها و ذخیره

- زنجیره کردن متدها داخل پرانتز، کد را خوانا نگه می‌دارد
- index=False تا شماره‌ی سطرها ستون اضافه نشود
- از Pandas 3، ستون‌های متنی با نوع str نمایش داده می‌شوند

```
clean = (
    df.drop(columns=["mass_band"])
      .rename(columns={"flipper_length_mm":
                       "flipper_mm"})
      .sort_values("body_mass_g",
                   ascending=False)
)
clean.to_csv("penguins_processed.csv",
             index=False)
```

جمع‌بندی و تمرین

۱. بعد از خواندن داده: describe، info، head، shape و isna().sum()

۲. loc بر اساس برچسب، iloc بر اساس موقعیت

۳. عملیات برداری را به apply ترجیح دهید

۴. تمرین: سنگین‌ترین پنگوئن ماده‌ی هر جزیره را پیدا کنید

۵. تمرین: چند درصد پنگوئن‌های Biscoe بیش از ۵ کیلوگرم‌اند؟

۶. نوت‌بوک: notebooks/02_pandas_fundamentals.ipynb