جلسه‌ی ۳

۳

پاک‌سازی داده

Garbage in, garbage out: مدل خوب روی داده‌ی بد، نتیجه‌ی بد می‌دهد

داده‌ی این جلسه: سفارش‌های یک فروشگاه اینترنتی

۱ ساختگی و آموزشی

۱۲۱۸ سفارش در یک سال از ۱ فروردین ۱۴۰۳، با همه‌ی مشکلات رایج داده‌ی واقعی

۲ نوع نادرست

مبلغ به‌صورت متن با جداکننده‌ی هزارگان («720,000») و تاریخ به‌صورت متن

۳ متن ناسازگار

Tehran، tehran، TEHRAN و « Tehran»؛ Esfahan و Mashad؛ Card و COD

۴ مقادیر گمشده

امتیاز، شهر و روش پرداخت

۵ مقادیر غیرممکن

تعداد منفی، امتیاز ۵۰ از ۵، ارسال ۱۲۰ روزه

۶ تکرار

۱۸ سفارش دو بار ثبت شده‌اند

ترتیب درست پاک‌سازی

۱ **کپی** — داده‌ی خام دست‌نخورده بماند

۲ **تکرارها** — اول حذف، بعد یکتایی کلید

۳ **نوع** — عدد، تاریخ، دسته

۴ **متن** — strip، title، یکی کردن املا

۵ **غیرممکن** — با دانش دامنه

۶ **گمشده** — اول «چرا؟»، بعد راهبرد

۷ **اعتبارسنجی** — assert

چرا تکرارها اول؟ اگر قبل از حذف تکرار، میانگین یا مقدار گمشده را حساب کنیم، سطرهای تکراری وزن بیشتری می‌گیرند.

متن به عدد و تاریخ

- to_numeric با errors="coerce" برای پیدا کردن مقادیر مشکل‌دار
- بعد از رفع مشکل، بدون coerce تبدیل کنید تا خطای بعدی پنهان نماند
- format صریح در to_datetime: سریع‌تر و بدون تفسیر اشتباه
- از ستون تاریخ: ماه، روز هفته و ساعت

```
bad = pd.to_numeric(df["total_price"],
                    errors="coerce").isna()
df.loc[bad, "total_price"].head()
# ['720,000', '6,080,000', ...]

df["total_price"] = (df["total_price"]
    .astype(str)
    .str.replace(",", "", regex=False)
    .astype("int64"))

df["order_date"] = pd.to_datetime(
    df["order_date"], format="%Y-%m-%d %H:%M")
```

یکسان‌سازی متن

- ۱۸ نوشتار مختلف برای ۸ شهر
- اگر بدون یکسان‌سازی گروه‌بندی کنیم، فروش تهران چند تکه می‌شود
- دو مرحله: فاصله و حروف، بعد دیکشنری املاها

```
df["city"] = (df["city"]
    .str.strip()
    .str.title()
    .replace({"Esfahan": "Isfahan",
              "Mashad": "Mashhad"}))

df["payment_method"] = (df["payment_method"]
    .str.strip().str.lower()
    .replace({"cod": "cash_on_delivery"}))
```

پرت با غلط یکی نیست

۱ قاعده‌ی IQR

خارج از بازه‌ی Q1 − 1.5×IQR تا Q3 + 1.5×IQR پرت است. برخلاف روش میانگین و انحراف معیار، خودش تحت تأثیر داده‌ی پرت قرار نمی‌گیرد.

۲ ارسال ۹ تا ۱۵ روزه

طبق IQR پرت است اما کاملاً ممکن (شهر دور، نوروز). داده‌ی واقعی است و حذف نمی‌شود.

۳ ارسال ۱۲۰ روزه، امتیاز ۵۰

غیرممکن است؛ به NaN تبدیل می‌شود تا بقیه‌ی اطلاعات سفارش حفظ شود (mask و where).

۴ تعداد منفی

مبلغ آن سفارش هم قابل‌اعتماد نیست؛ کل سطر حذف می‌شود.

برای هر ستون گمشده، اول بپرسید چرا

ستون	دلیل احتمالی	راهبرد
rating	مشتری امتیاز نداده؛ خودش یک اطلاع است	پر نمی‌کنیم؛ ستون پرچم has_rating
city	در سفارش‌های دیگر همان مشتری هست	پر کردن از شهر رایج همان مشتری
payment_method	تعداد کم، دلیل نامعلوم	مقدار "unknown"
delivery_days	چند مقدار غیرممکن که حذف شدند	میانه (مقاوم به پرت)

پر کردن امتیاز با میانگین، این واقعیت را که بسیاری امتیاز نمی‌دهند پنهان می‌کند و توزیع امتیازها را مصنوعی می‌سازد.

اعتبارسنجی و تابع تکرارپذیر

- قواعد داده‌ی تمیز را صریح با assert بنویسید
- کل فرایند را در یک تابع بگذارید تا روی نسخه‌ی جدید داده هم اجرا شود
- خروجی: data/orders_clean.csv برای جلسه‌های بعد

```
assert df["order_id"].is_unique
assert (df["quantity"] > 0).all()
assert df["rating"].dropna().between(1, 5).all()
assert df["city"].notna().all()

def clean_orders(raw):
    df = raw.drop_duplicates().copy()
    ...
    return df.reset_index(drop=True)
```

چک‌لیست پاک‌سازی و تمرین

۱. خام را نگه دارید؛ تکرار، نوع، متن، غیرممکن، گمشده، اعتبارسنجی

۲. پرت را با غلط اشتباه نگیرید؛ دانش دامنه تصمیم می‌گیرد

۳. تمرین: delivery_days گمشده را با میانه‌ی همان شهر پر کنید (transform)

۴. تمرین: سفارش‌های پرت از نظر مبلغ را پیدا کنید؛ غلط‌اند یا واقعی؟

۵. تمرین: تابع clean_orders گزارش سطرهای حذف‌شده در هر مرحله را چاپ کند

۶. نوت‌بوک: notebooks/03_data_cleaning.ipynb