جلسه‌ی ۴

۴

گروه‌بندی، ادغام و تغییر شکل

پاسخ به سؤال‌های «به تفکیک»: فروش به تفکیک شهر، امتیاز به تفکیک دسته، رشد به تفکیک ماه

ترم دوم: علم داده | کیوان محمودی

انواع ادغام با merge

نوع	سطرهایی که نگه داشته می‌شوند
inner	فقط کلیدهایی که در هر دو جدول هستند
left	همه‌ی سطرهای جدول چپ؛ بدون تطابق ← NaN
right	برعکس left
outer	همه‌ی سطرهای هر دو جدول

validate="many_to_one" جلوی تکثیر بی‌صدای سطرها را می‌گیرد و indicator=True منشأ هر سطر را نشان می‌دهد؛ مثلاً ۲۲ مشتری که هیچ سفارشی نداده‌اند.

groupby: تقسیم، اعمال، ترکیب

۱

تقسیم

سطرها بر اساس مقدار city به گروه‌ها تقسیم می‌شوند

›

۲

اعمال

روی total_price هر گروه، sum حساب می‌شود

›

۳

ترکیب

نتایج در یک Series با index شهرها برمی‌گردد

```
df.groupby("city")["total_price"].sum()
```

تجمیع نام‌دار

- نام ستون خروجی، ستون ورودی و تابع، صریح و خوانا
- گروه‌بندی چندستونی ← unstack ← MultiIndex
- filter برای نگه داشتن گروه‌هایی با یک شرط

```
city_report = df.groupby("city").agg(
    orders=("order_id", "count"),
    customers=("customer_id", "nunique"),
    avg_basket=("total_price", "mean"),
    avg_rating=("rating", "mean"),
)

loyal = df.groupby("customer_id").filter(
    lambda g: len(g) >= 10)
```

agg یا transform؟

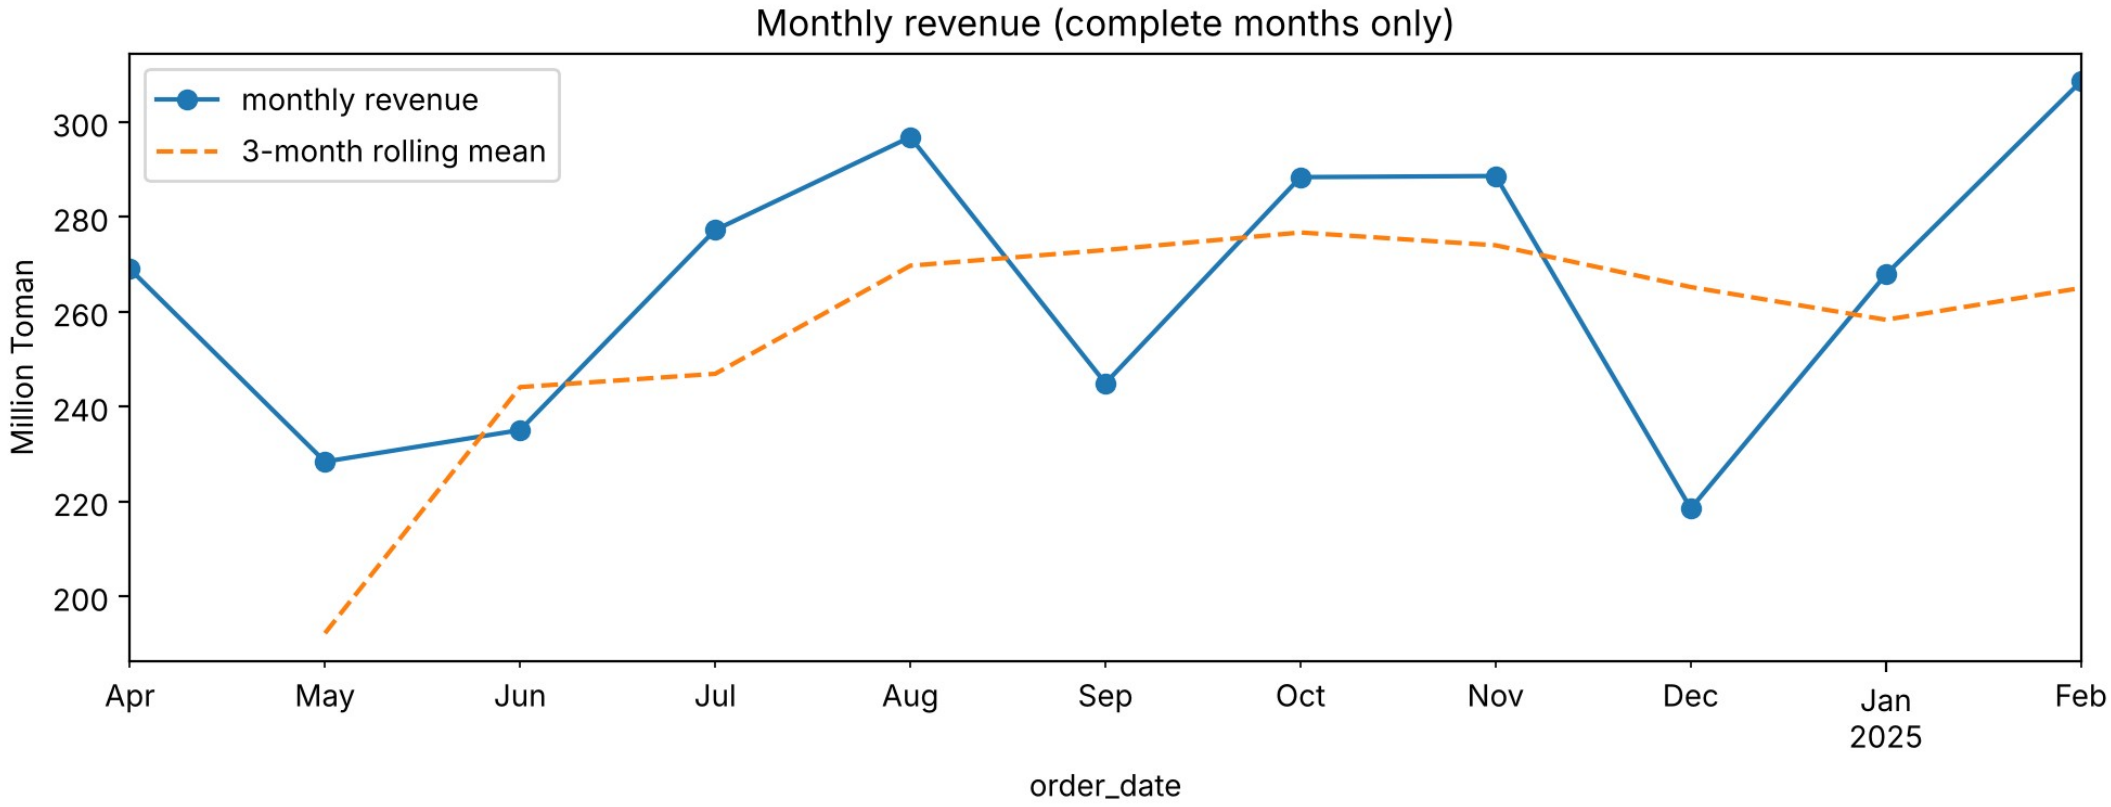
۱ agg

برای هر گروه یک مقدار. خروجی به تعداد گروه‌ها سطر دارد. مناسب گزارش خلاصه.

۲ transform

نتیجه‌ی گروه را به تک‌تک سطرهای آن برمی‌گرداند. مناسب مقایسه‌ی هر سطر با گروهش: «این سفارش چند برابر میانگین دسته‌ی خودش است؟»

سری زمانی با resample



دام رایج: ماه اول و آخر داده ناقص‌اند و «رشد ۲۳۹٪» ساختگی است. در نمودار فقط ماه‌های کامل آمده‌اند؛ خط‌چین میانگین متحرک سه‌ماهه است.

داده‌ی پهن و بلند

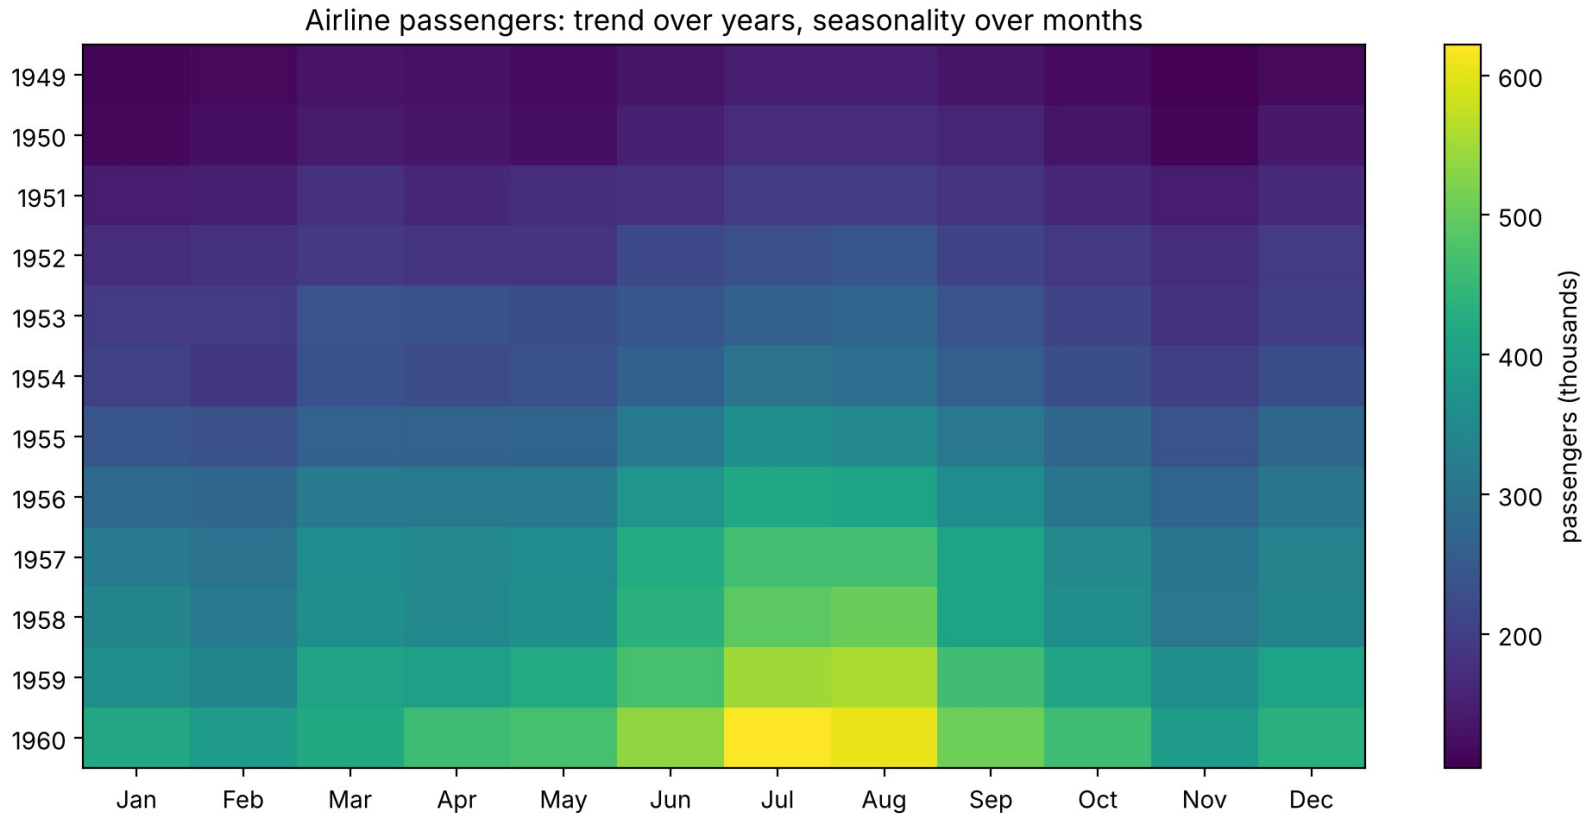
۱ پهن (wide)

هر متغیر یک ستون؛ برای خواندن انسان راحت. ساختن با pivot یا pivot_table.

۲ بلند (long)

هر سطر یک مشاهده؛ مناسب Seaborn، گروه‌بندی و پایگاه داده. ساختن با melt.

روند و فصلی بودن در یک نگاه



داده‌ی flights بعد از pivot: روشن‌تر شدن از بالا به پایین روند سالانه را نشان می‌دهد و ستون‌های تیر و مرداد فصلی بودن را.

جمع‌بندی و تمرین

۱. merge با validate؛ همیشه تعداد سطرها را بعد از ادغام بررسی کنید

۲. agg برای خلاصه، transform برای برگرداندن به سطرها، filter برای حذف گروه‌ها

۳. pivot_table و crosstab برای گزارش دوبعدی؛ resample برای زمان

۴. تمرین: پرفروش‌ترین کالای هر دسته را پیدا کنید (idxmax)

۵. تمرین: جدول تعداد سفارش برای روز هفته × ساعت روز

۶. نوت‌بوک: notebooks/04_groupby_merge_reshape.ipynb