جلسه‌ی ۶

۶

تحلیل اکتشافی داده (EDA)

مطالعه‌ی موردی: قیمت ۵۴ هزار الماس به چه چیزهایی بستگی دارد؟

ترم دوم: علم داده | کیوان محمودی

EDA یعنی گفت‌وگو با داده

۱
سؤال
مسئله را روشن کنید

۲
کیفیت
گمشده، تکرار، غیرممکن

۳
هدف
توزیع و تبدیل

۴
تک‌متغیره
هر ویژگی جدا

۵
دومتغیره
رابطه با هدف

۶
مخدوش‌کنند ه
قبل از نتیجه‌گیری

۷
گزارش
به زبان ساده

کیفیت داده

۱۴۶

سطر کاملاً تکراری

۲۲

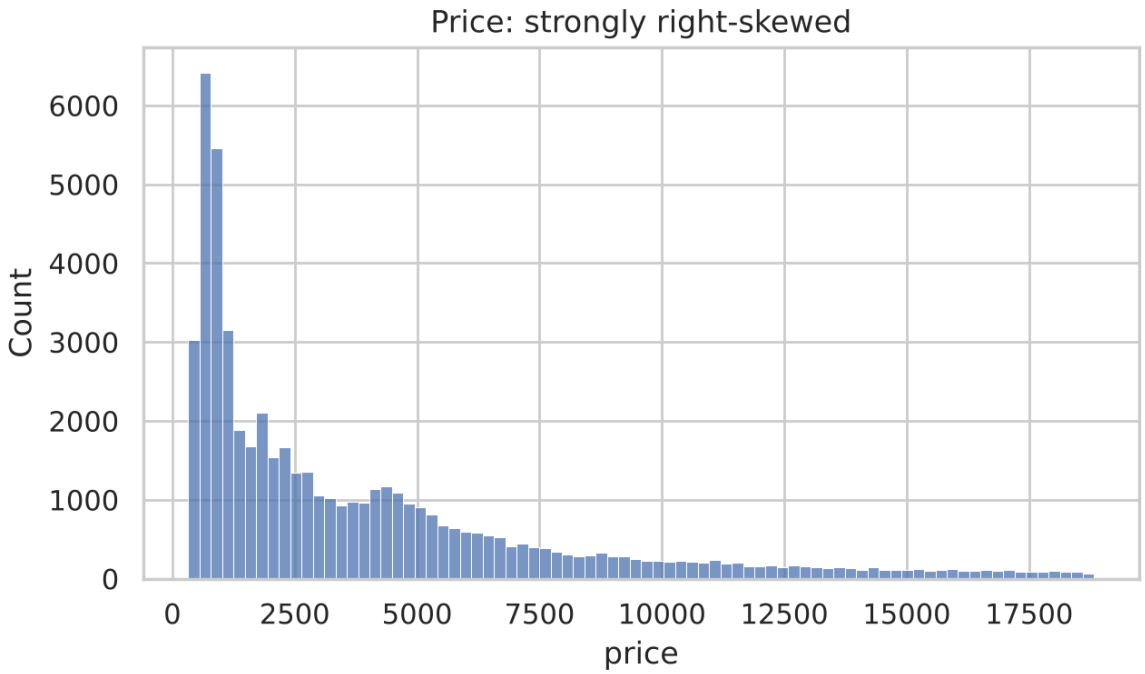
الماس با بُعد صفر یا ۵۹ میلی‌متری

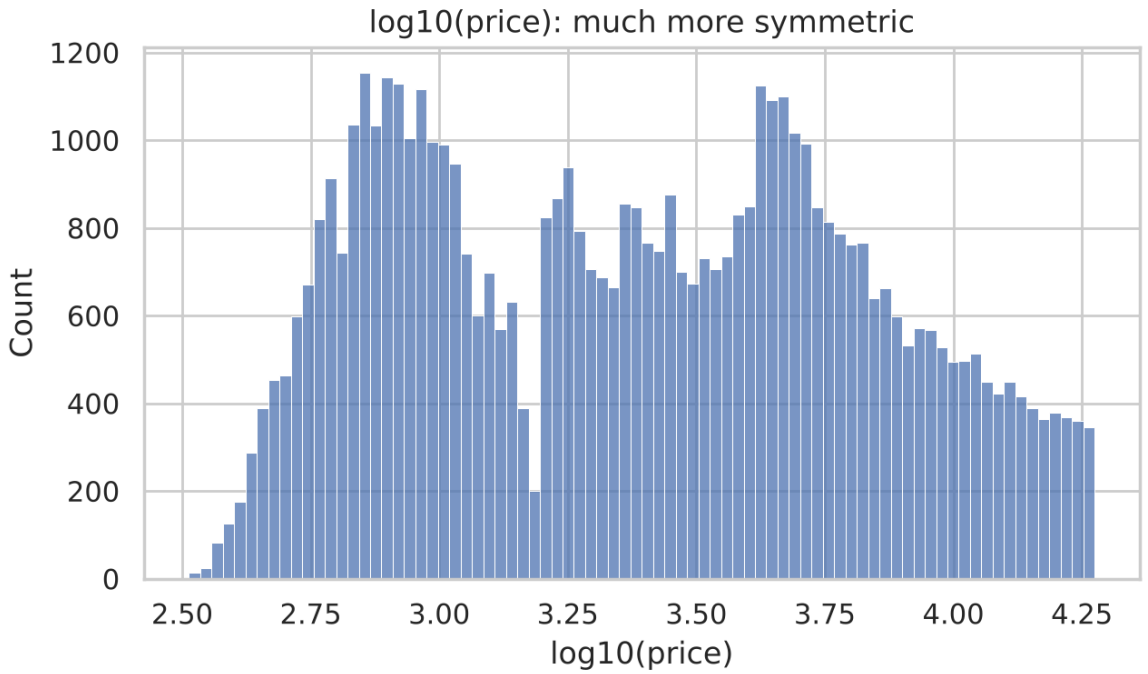
۵۳,۷۷۲

سطر معتبر باقی‌مانده

cut، color و clarity متغیر ترتیبی‌اند؛ با pd.Categorical(..., ordered=True) ترتیبشان را مشخص می‌کنیم تا مرتب‌سازی و نمودارها منطقی باشند.

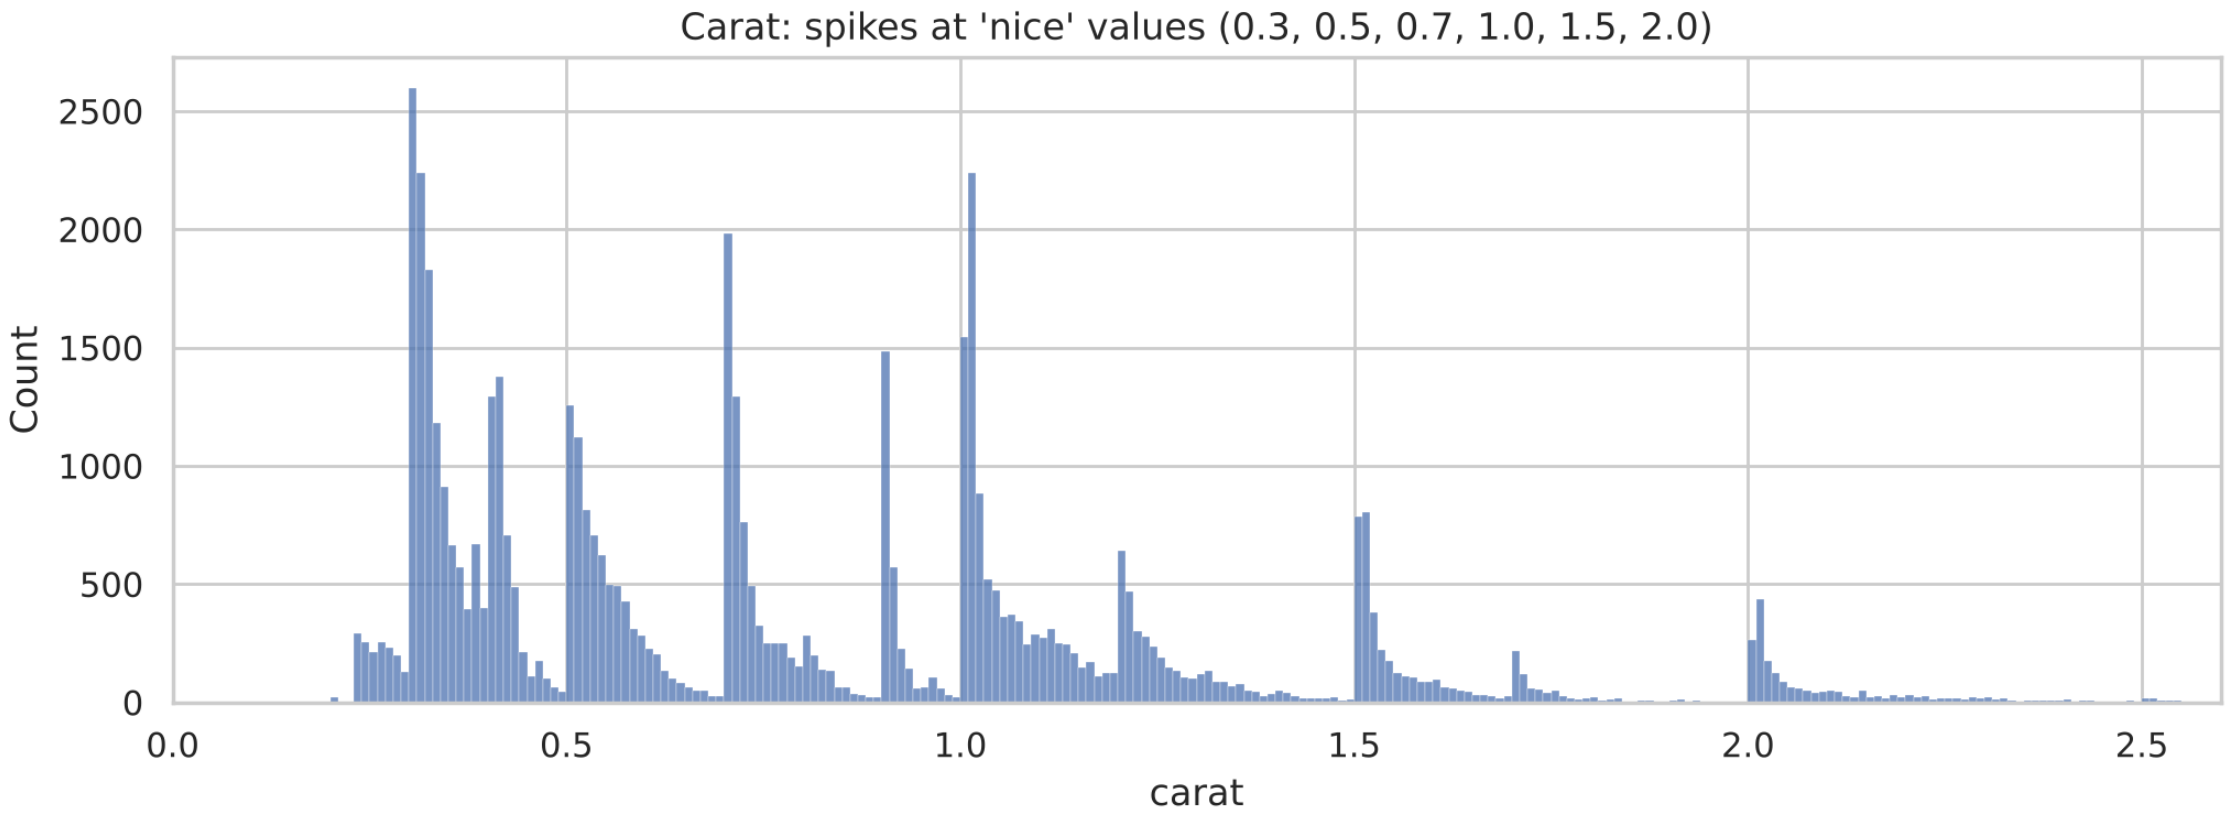
توزیع قیمت: چوله به راست





میانگین حدود ۳۹۰۰ و میانه حدود ۲۴۰۰. برای داده‌ی چوله، میانه معرف بهتری است. لگاریتم تغییر ضربی قیمت را جمعی و توزیع را متقارن‌تر می‌کند.

یک جزئیات انسانی



جهش‌ها درست روی وزن‌های رُند: احتمالاً سنگ را کمی سنگین‌تر از ۱ قیراط تراش می‌دهند تا با برچسب «۱ قیراط» فروخته شود.

معما: بهترین تراش، ارزان‌ترین؟



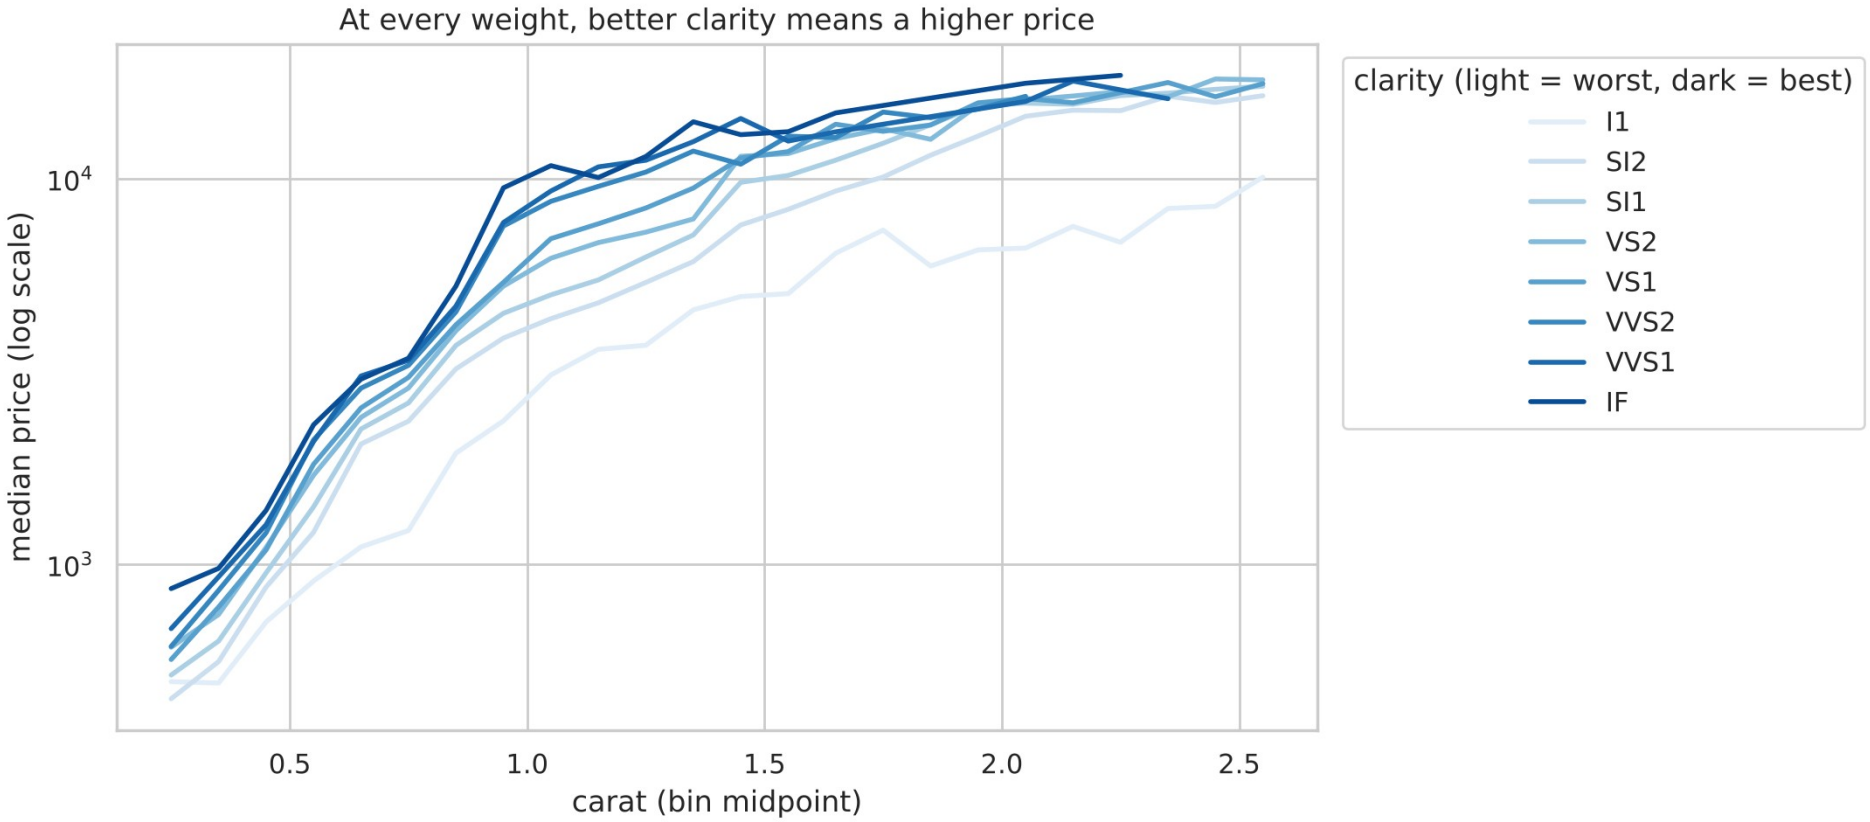
میانه‌ی قیمت Ideal کمترین است و Fair جزو گران‌ترین‌ها. رنگ هم همین‌طور: J (بدترین) گران‌ترین و D (بهترین) ارزان‌ترین.

حل معما: متغیر مخدوش‌کننده

تراش	میانه‌ی وزن	میانه‌ی قیمت (همه)	میانه‌ی قیمت (۰٫۹ تا ۱٫۱ قیراط)
Fair	1.00	3282	3733
Good	0.82	3038	4311
Very Good	0.71	2647	4690
Premium	0.85	3178	4672
Ideal	0.54	1813	5222

وزن هم روی قیمت اثر دارد و هم با کیفیت تراش مرتبط است. با ثابت نگه داشتن وزن، ترتیب برعکس می‌شود و Ideal گران‌ترین است.

در هر وزن، کیفیت بهتر یعنی قیمت بیشتر



متغیر ترتیبی با طیف تک‌رنگ: روشن برای بدترین شفافیت و تیره برای بهترین.

گزارش یافته‌ها برای مدیر

۱ **وزن، عامل اصلی قیمت است** با دو برابر شدن وزن، قیمت حدود سه برابر می‌شود

۲ **در وزن یکسان، کیفیت بهتر گران‌تر است** تراش، رنگ و شفافیت

۳ **مقایسه‌ی ساده‌ی میانگین‌ها گمراه‌کننده است** الماس‌های باکیفیت این داده کوچک‌ترند

۴ **اثر روانی وزن‌های رُند** الماس‌های درست بالای ۱٫۰ و ۱٫۵ قیراط بسیار بیشترند

۵ **کیفیت داده** ۱۴۶ تکراری و ۲۲ سطر با ابعاد غیرممکن حذف شدند

جمع‌بندی و تمرین

۱. قبل از هر نتیجه‌گیری، به دنبال متغیر مخدوش‌کننده بگردید

۲. برای حذف اثر یک متغیر: ثابت نگه داشتن، ویژگی نسبی، یا رسم برای هر گروه

۳. تمرین: نشان دهید در وزن ثابت، رنگ D گران‌تر از J است

۴. تمرین: اختلاف قیمت ۰٫۹۵ تا ۰٫۹۹ و ۱٫۰۰ تا ۱٫۰۴ قیراط چقدر است؟

۵. تمرین: یک EDA کوتاه روی tips با سه یافته‌ی اصلی

۶. نوت‌بوک: notebooks/06_exploratory_data_analysis.ipynb