جلسه‌ی ۸

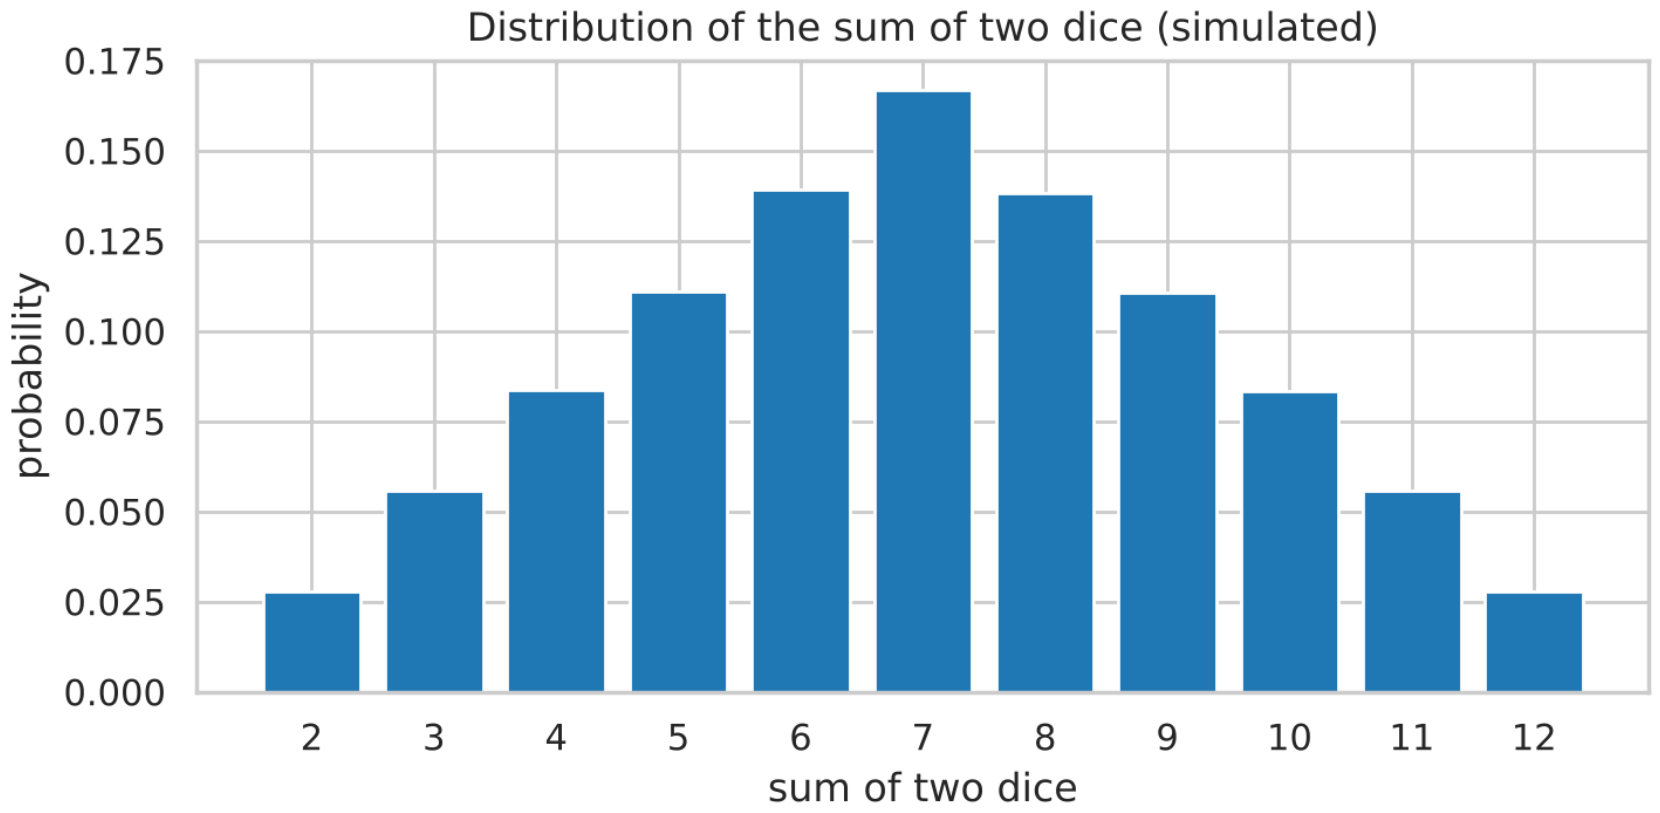
۸

احتمال برای علم داده

زبان عدم قطعیت؛ پایه‌ی آمار و یادگیری ماشین

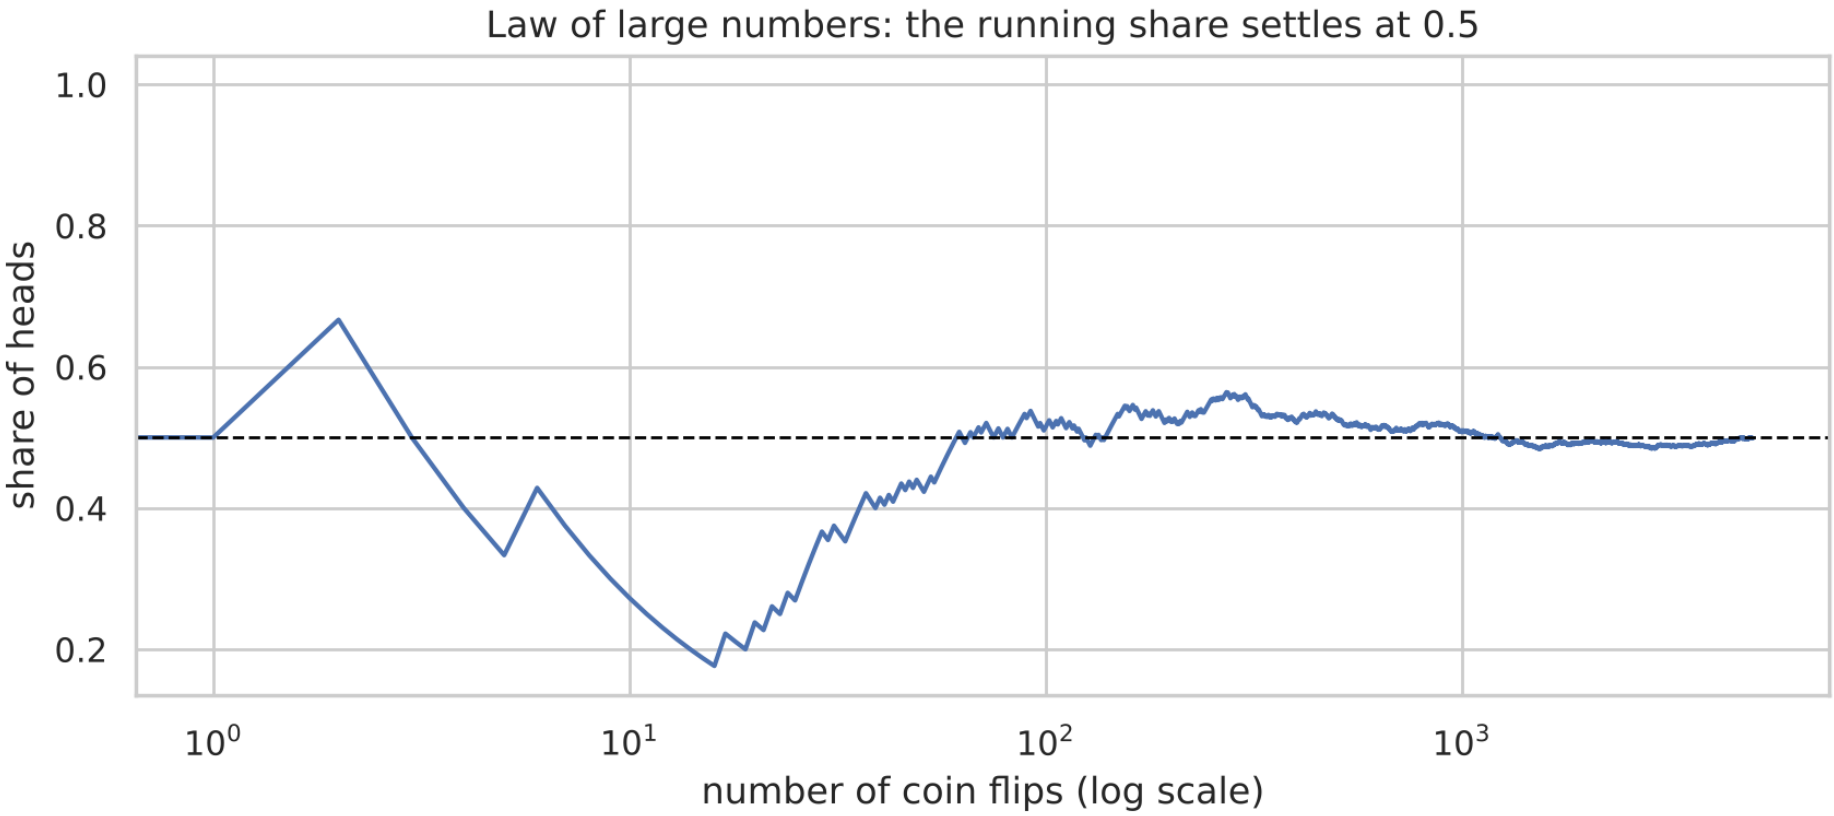
ترم دوم: علم داده | کیوان محمودی

شبیه‌سازی: احتمال با کامپیوتر



یک میلیون پرتاب دو تاس: احتمال جمع ۷ برابر ۰٫۱۶۶۷ شد، دقیقاً همان ۶/۳۶. وقتی محاسبه‌ی دقیق سخت است، شبیه‌سازی کنید.

قانون اعداد بزرگ



با افزایش تکرار، فراوانی نسبی به احتمال واقعی نزدیک می‌شود. به همین دلیل نتیجه‌گیری از نمونه‌ی کوچک خطرناک است.

شهود ما در احتمال اغلب اشتباه می‌کند

۵۰٪

احتمال تولد یکسان دو نفر در کلاس ۲۳ نفره

۲۵۳

جفت مختلف در کلاس ۲۳ نفره

۹۷٪

همین احتمال در کلاس ۵۰ نفره

بیشتر افراد حدس می‌زنند حدود ۵٪. شبیه‌سازی یک راه مطمئن برای بررسی شهود است.

احتمال شرطی و استقلال

۱ P(survived)

۳۸٪ مسافران تایتانیک زنده ماندند

۲ P(survived | female)

۷۴٪

۳ P(survived | male)

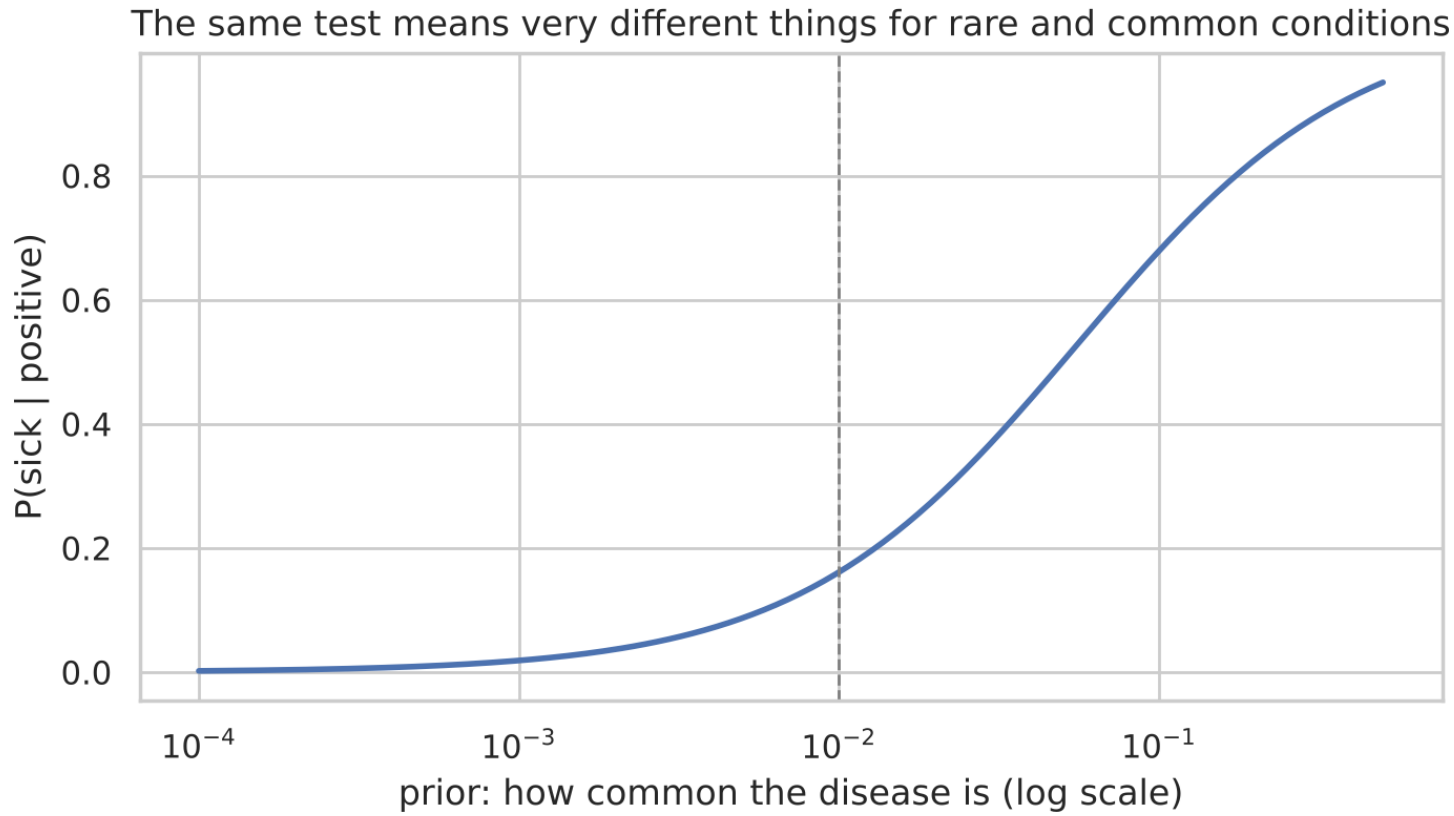
۱۹٪؛ پس جنسیت و زنده ماندن مستقل نیستند

قضیه‌ی بیز: آزمایش مثبت شد، بیمارم؟

	تعداد	آزمایش مثبت
بیمار (۱٪)	۱۰۰	۹۵
سالم (۹۹٪)	۹۹۰۰	۴۹۵
جمع	۱۰,۰۰۰	۵۹۰

حساسیت ۹۵٪ و مثبت کاذب ۵٪. از ۵۹۰ نتیجه‌ی مثبت فقط ۹۵ نفر بیمارند: P(بیمار | مثبت) ≈ ۱۶٪. نادیده گرفتن نرخ پایه، خطای رایجی است.

معنای یک آزمایش به نرخ پایه بستگی دارد



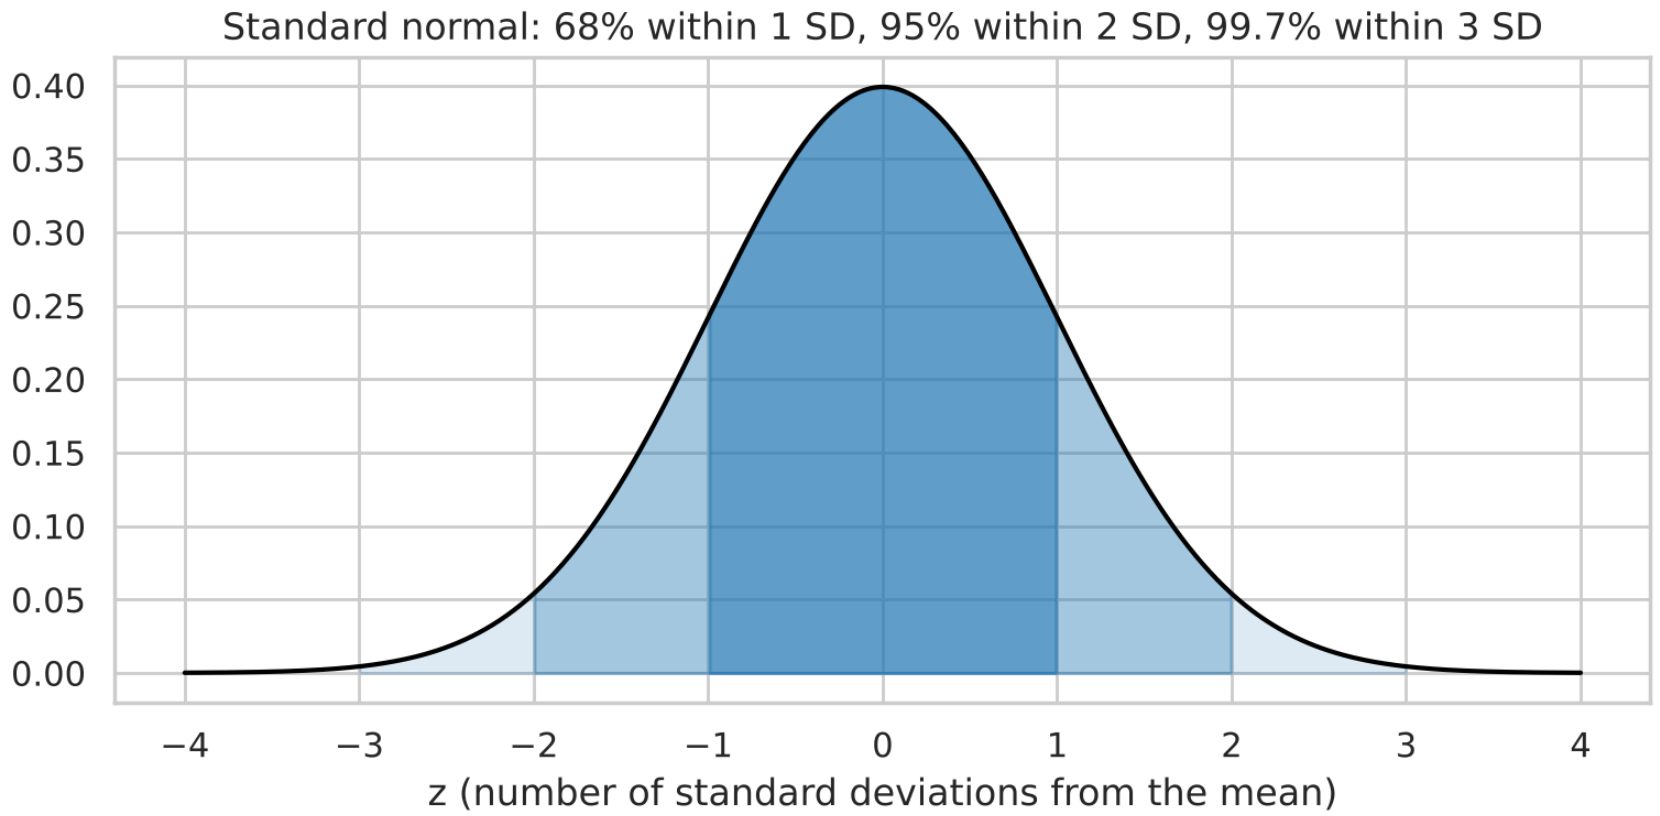
همین منطق در یادگیری ماشین: مدل تشخیص تقلب با دقت بالا، روی داده‌ای با ۰٫۱٪ تقلب، هشدار کاذب زیادی می‌سازد.

توزیع‌های مهم

توزیع	چه چیزی را مدل می‌کند	مثال
برنولی	یک آزمایش با دو نتیجه	کلیک روی تبلیغ
دوجمله‌ای	تعداد موفقیت در n آزمایش	خریدار از ۱۰۰ بازدیدکننده
پواسون	تعداد رخداد در یک بازه	سفارش در یک ساعت
نرمال	مجموع اثرهای کوچک زیاد	قد، خطای اندازه‌گیری
نمایی	زمان انتظار تا رخداد بعدی	فاصله‌ی دو سفارش

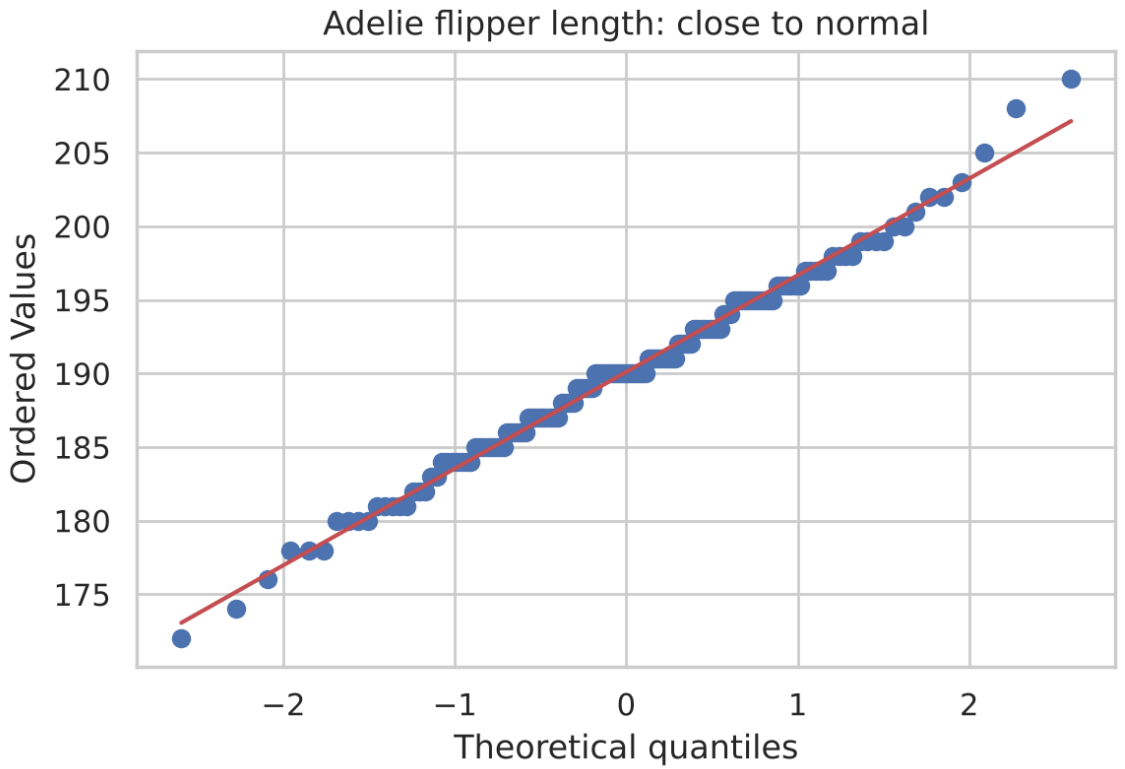
در scipy.stats همه یک رابط دارند: pmf/pdf، cdf، ppf، sf و rvs.

توزیع نرمال: قاعده‌ی ۶۸-۹۵-۹۹٫۷



قد با میانگین ۱۷۴ و انحراف معیار ۷: حدود ۱٪ بلندتر از ۱۹۰ سانتی‌متر؛ صدک ۹۰ برابر ۱۸۳ سانتی‌متر (ppf).

آیا داده‌ی واقعی نرمال است؟





در نمودار Q-Q، نقاط روی خط یعنی تقریباً نرمال. طول باله‌ی پنگوئن‌ها نرمال است؛ قیمت الماس اصلاً نیست.

جمع‌بندی و تمرین

۱. وقتی محاسبه سخت است، شبیه‌سازی کنید

۲. در احتمال شرطی و بیز، همیشه به نرخ پایه توجه کنید

۳. امید ریاضی میانگین بلندمدت است؛ واریانس میزان ریسک

۴. تمرین: احتمال حداقل ۳ شیر پشت سر هم در ۱۰ پرتاب سکه

۵. تمرین: اگر آزمایش دوم هم مثبت شود، احتمال بیماری چقدر است؟

۶. نوت‌بوک: notebooks/08_probability.ipynb