جلسه‌ی ۱۰

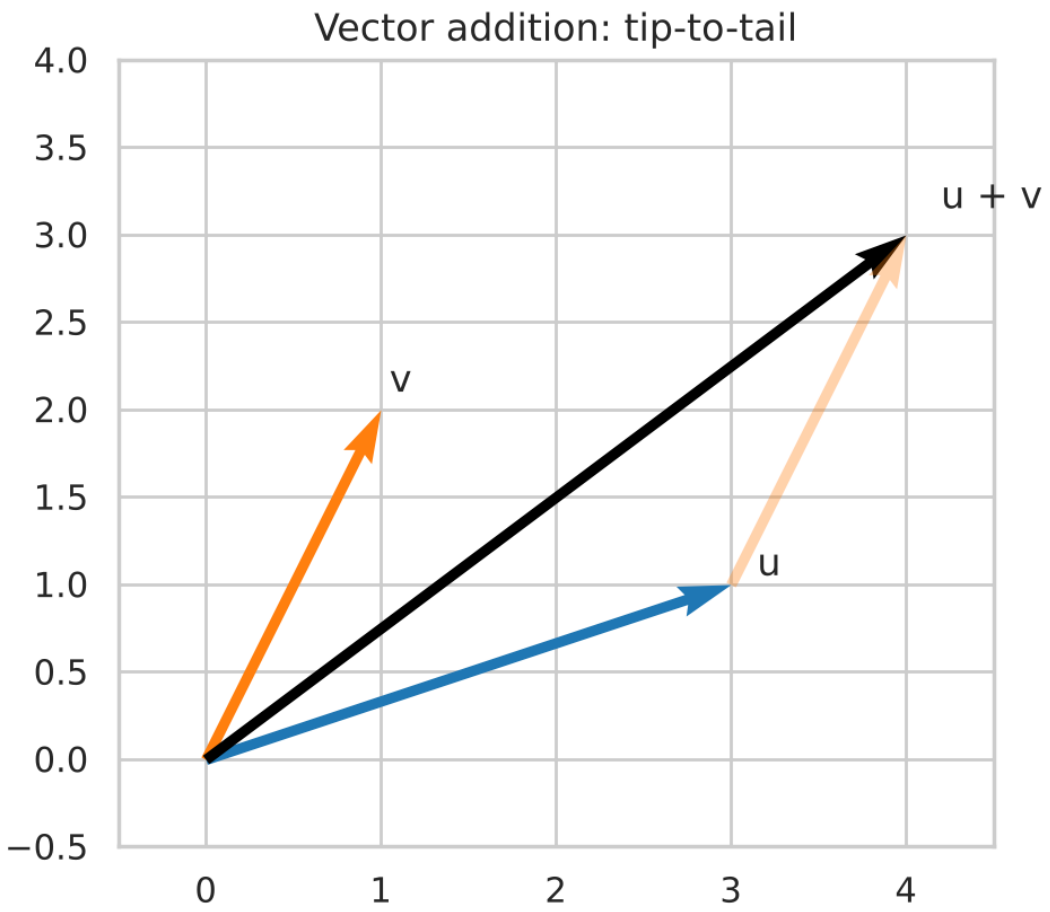
۱۰

# جبر خطی پایه برای علم داده

هر جدول یک ماتریس است و هر سطر یک بردار

ترم دوم: علم داده | کیوان محمودی

# بردار




۱ **بردار** فهرستی مرتب از اعداد؛ یک سطر از جدول

۲ **جمع** عنصربه‌عنصر؛ هندسی: سر به ته

۳ **نُرم** طول بردار: $\|v\| = \sqrt{(v_1^2 + v_2^2 + \dots)}$

۴ **ضرب داخلی** $u \cdot v = \|u\|\|v\|\cos\theta$

# شباهت کسینوسی: متن به بردار

| | d1 | d2 | d3 | d4 |
|---|---|---|---|---|
| d1: data science uses statistics and python | 1.00 | 0.67 | 0.00 | 0.57 |
| d2: python and statistics for data analysis | 0.67 | 1.00 | 0.00 | 0.57 |
| d3: the football match ended with a late goal | 0.00 | 0.00 | 1.00 | 0.00 |
| d4: statistics statistics statistics data data | 0.57 | 0.57 | 0.00 | 1.00 |

cos θ = u·v / (‖u‖‖v‖). به جهت حساس است نه طول. مدل‌های زبانی امروزی هم embeddingها را با همین معیار مقایسه می‌کنند.

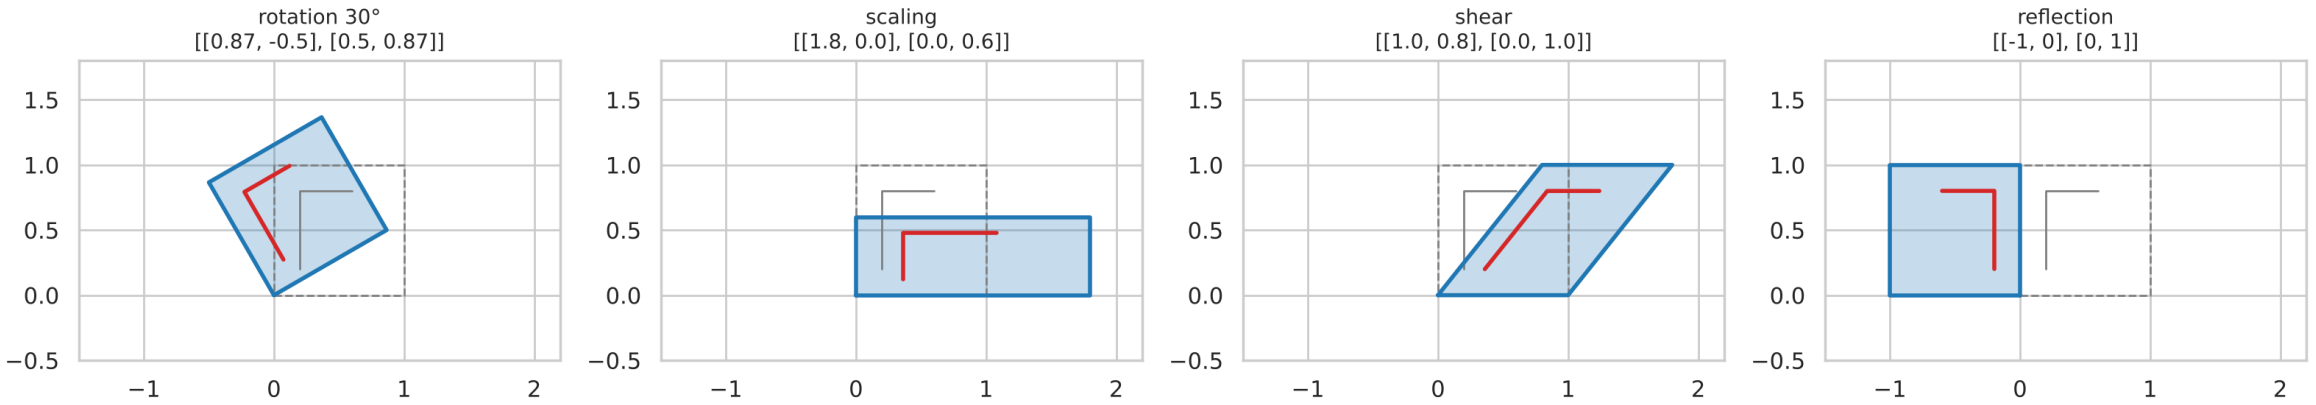
# ضرب ماتریسی

- $(m \times p) \leftarrow (n \times p) \ @ \ (m \times n)$
- A * B عنصربه‌عنصر است و A @ B ضرب ماتریسی
- ضرب ماتریسی جابه‌جایی‌پذیر نیست: $AB \neq BA$
- پیش‌بینی مدل خطی و هر لایه‌ی شبکه‌ی عصبی، یک ضرب ماتریسی است

```
A = np.array([[1, 2], [3, 4]])
B = np.array([[0, 1], [1, 0]])

A @ B      # [[2 1]
           #  [4 3]]
B @ A      # [[3 4]
           #  [1 2]]
A * B      # [[0 2]
           #  [3 0]]
```

# ماتریس به‌عنوان تبدیل




ستون‌های ماتریس نشان می‌دهند بردارهای پایه به کجا می‌روند. دترمینان ضریب تغییر مساحت است؛ دترمینان صفر یعنی ماتریس معکوس ندارد (در داده: ویژگی تکراری).

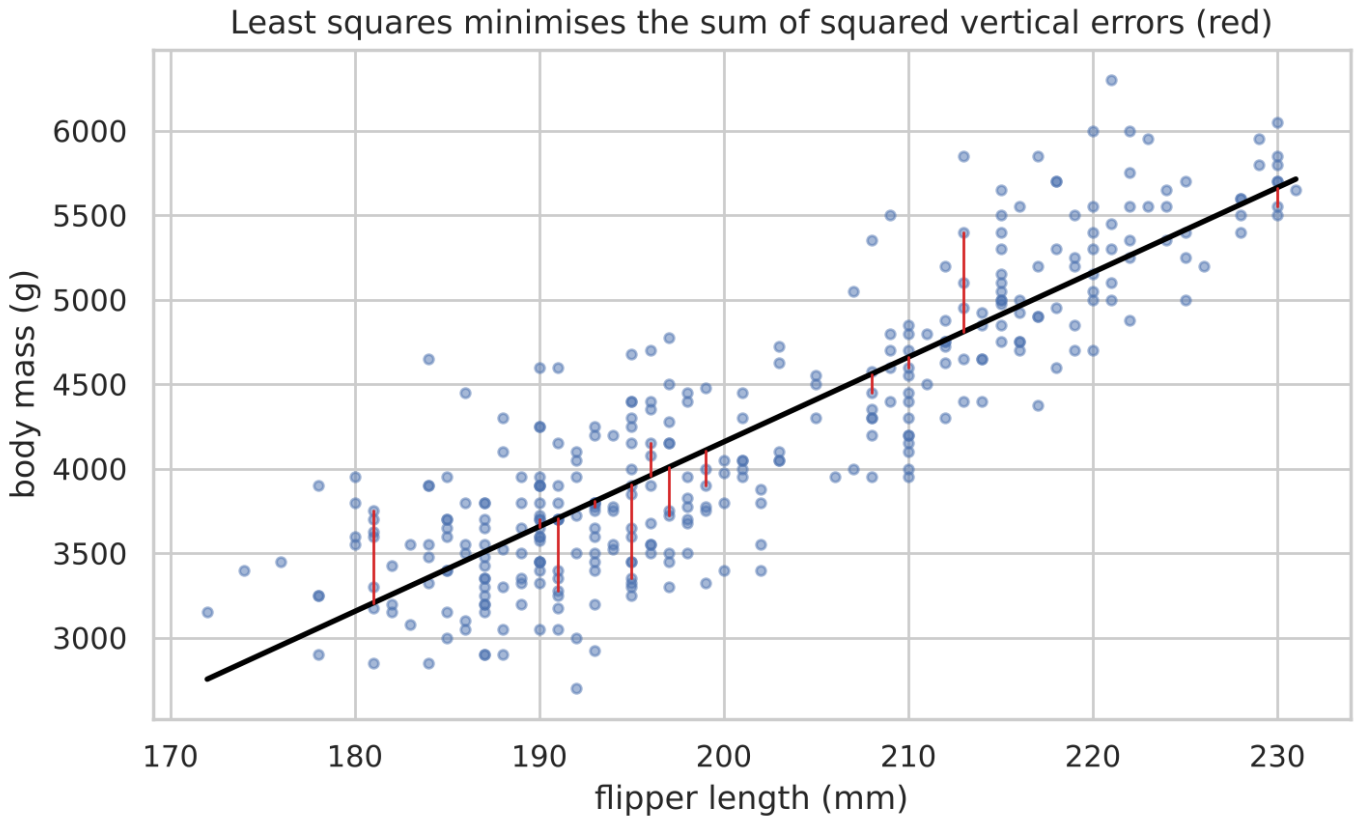
# حل دستگاه معادلات

- ۳ بسته‌ی A و ۲ بسته‌ی B: ۸۴۰ هزار تومان
- ۱ بسته‌ی A و ۴ بسته‌ی B: ۹۸۰ هزار تومان
- solve را به inv(A) @ y ترجیح دهید: سریع‌تر و پایدارتر

```
A = np.array([[3, 2],
              [1, 4]])
y = np.array([840, 980])

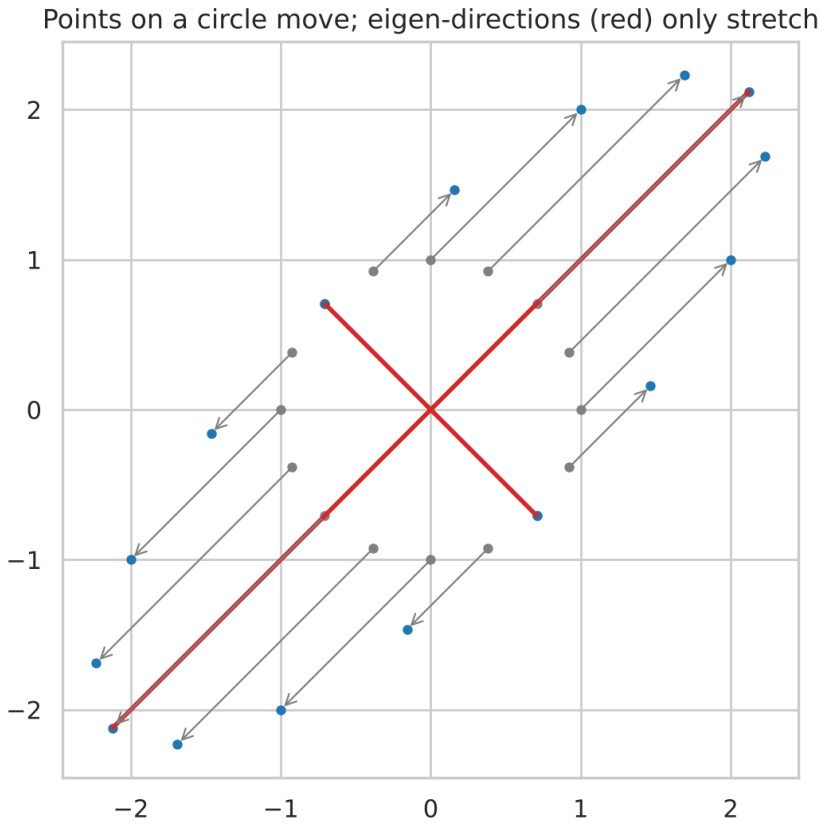
np.linalg.solve(A, y)
# [140. 210.]
```

# کمترین مربعات = رگرسیون خطی



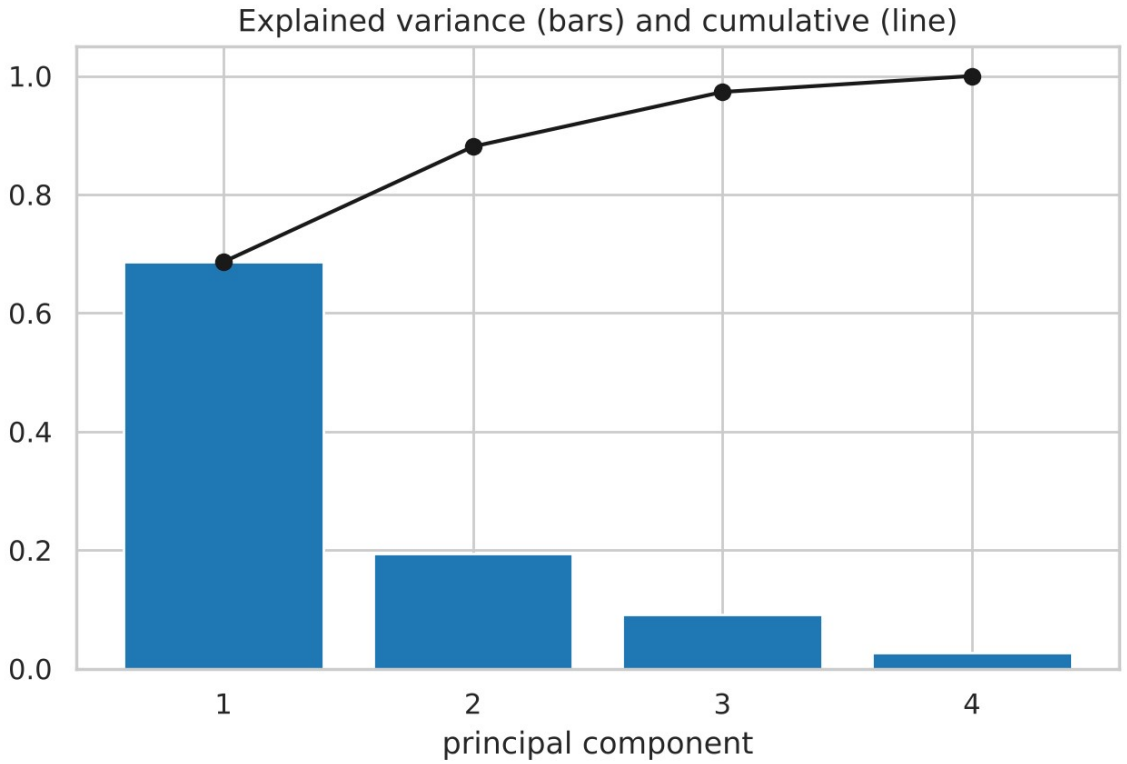

$X^TX\,\beta = X^Ty$. وزن ≈ −۵۸۷۲ + ۵۰٫۲ × طول باله؛ $R^2$ = ۰٫۷۶. همین مدل را ترم بعد با scikit-learn می‌سازیم.

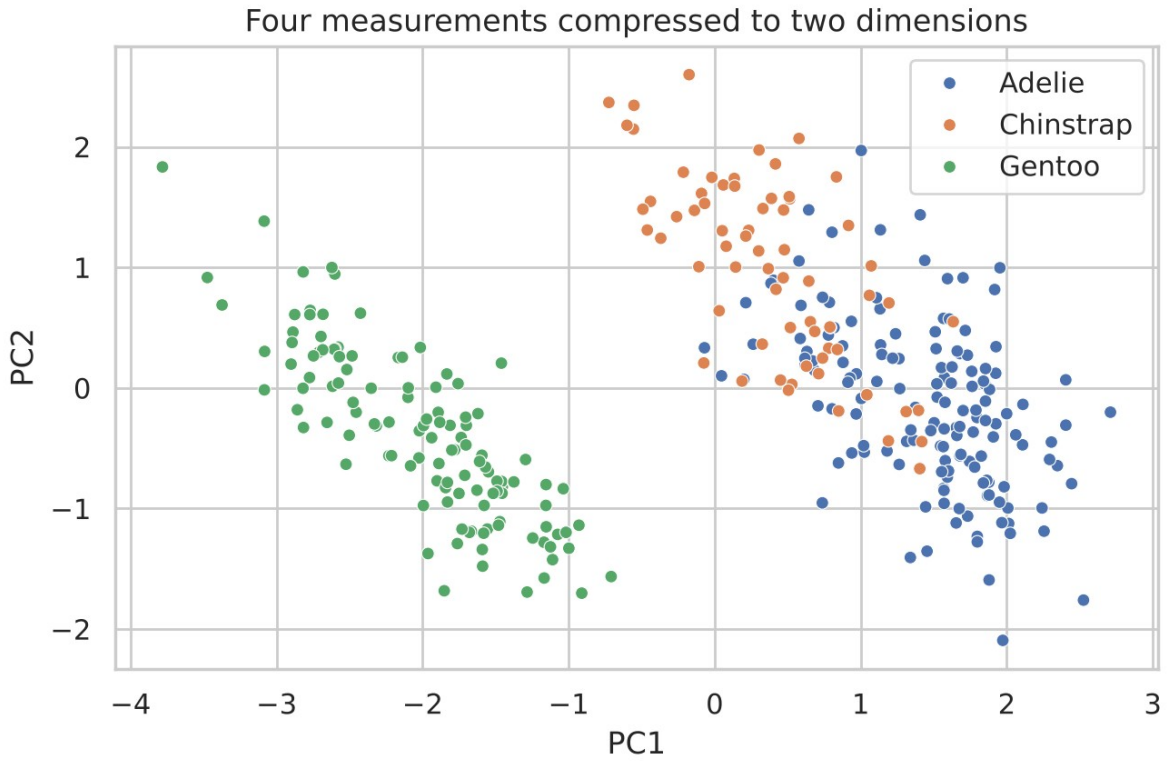
# مقدار ویژه و بردار ویژه




$Av = \lambda v$. دایره بیضی می‌شود و محورهای بیضی همان بردارهای ویژه‌اند: در جهت (۱،۱) سه برابر کشیده شده و در جهت (۱،-۱) بدون تغییر.

# PCA از صفر




بردارهای ویژه‌ی ماتریس کوواریانس، جهت‌های بیشترین پراکندگی‌اند. دو مؤلفه ۸۸٪ اطلاعات را نگه می‌دارند و سه گونه بدون برچسب از هم جدا می‌شوند.

# جمع‌بندی و تمرین

۱. بردار = مشاهده؛ شباهت کسینوسی = شباهت متن‌ها

۲. ضرب ماتریسی = پیش‌بینی مدل خطی؛ کمترین مربعات = رگرسیون

۳. مقدار و بردار ویژه = PCA و کاهش ابعاد

۴. تمرین: ماتریس دوران ۹۰ درجه را چهار بار اعمال کنید

۵. تمرین: PCA را بدون استانداردسازی تکرار کنید؛ چرا یک مؤلفه همه‌چیز را می‌گیرد؟

۶. نوت‌بوک: notebooks/10_linear_algebra.ipynb