جلسه‌ی ۱۱

۱۱

پروژه‌ی پایانی: سفرهای تاکسی نیویورک

یک تحلیل کامل از سؤال تا گزارش، با همه‌ی ابزارهای ترم

ترم دوم: علم داده | کیوان محمودی

سؤال‌ها

۱ **زمان** سفرها در چه ساعت‌ها و روزهایی متمرکزند؟

۲ **کرایه** چه رابطه‌ای با مسافت و مدت سفر دارد؟

۳ **انعام** مسافران چقدر انعام می‌دهند و به چه چیزی بستگی دارد؟

۴ **زرد یا سبز** آیا درصد انعام در دو نوع تاکسی متفاوت است؟

پاک‌سازی

۶۴۳۳

سفر در مارس ۲۰۱۹

۶۳

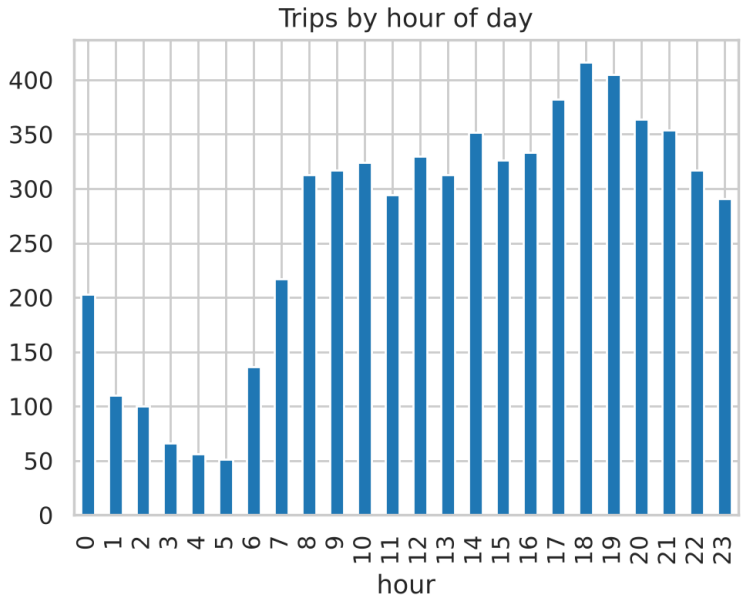
سفر با مدت یا مسافت صفر، خارج از بازه یا سرعت بیش از ۶۰ مایل

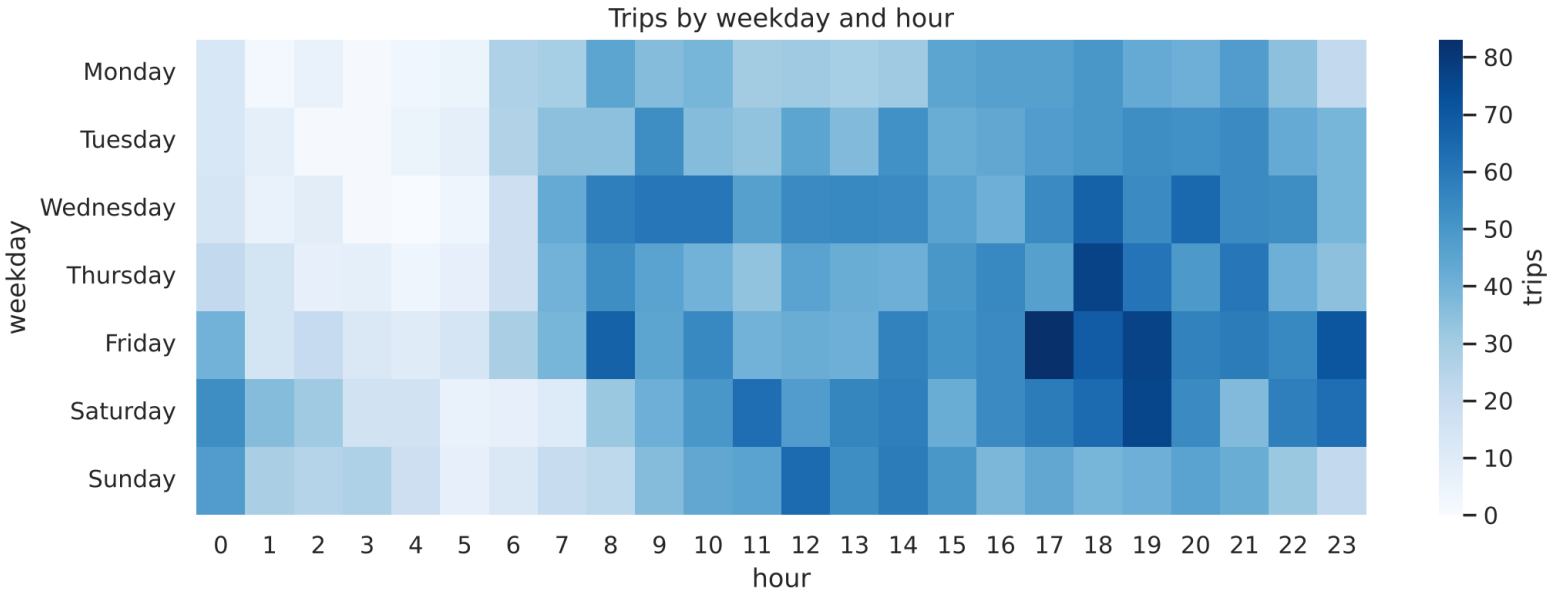
۹۹٪

داده‌ی نگه‌داشته‌شده

۹۶ سفر با تعداد مسافر صفر نگه داشته شدند: خطای ثبت راننده است، اما کرایه و انعامشان معتبر است. هر تصمیم مستند می‌شود.

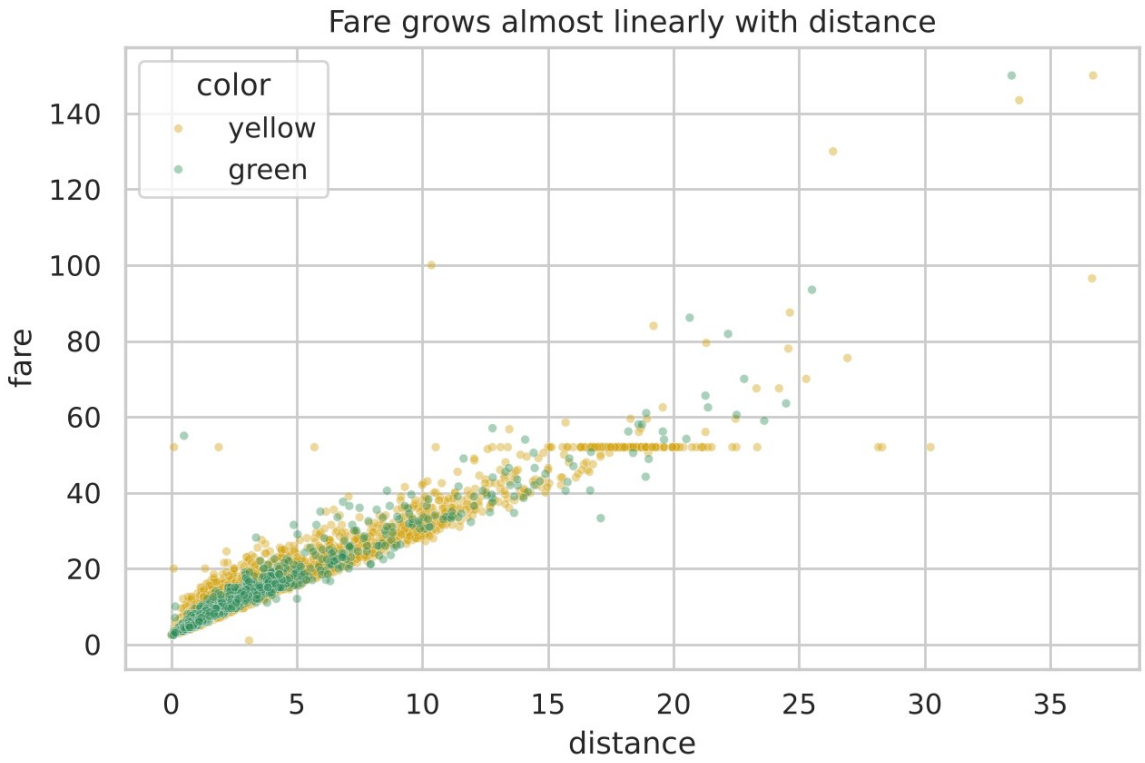
الگوی زمانی

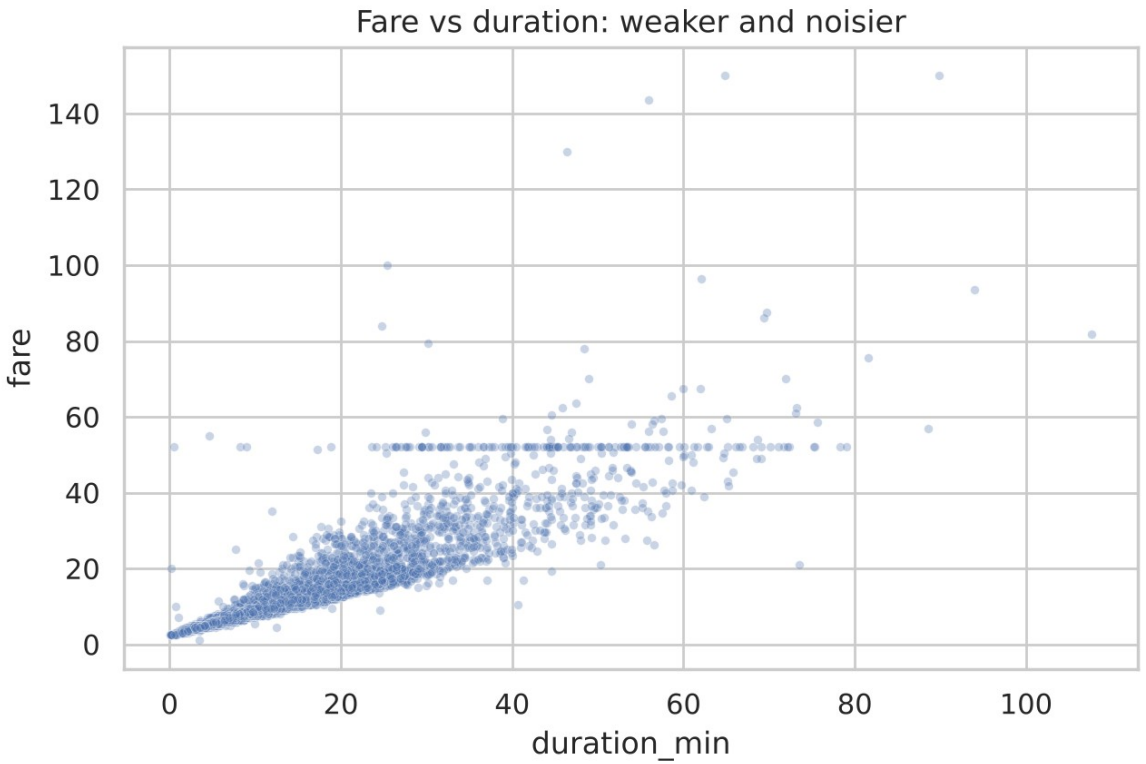




اوج عصرها (ساعت ۱۸ تا ۱۹)، کمترین در ۴ تا ۵ صبح. روزهای کاری اوج صبحگاهی دارند؛ آخر هفته‌ها سفرهای بامدادی بیشتر.

کرایه: ورودی + مسافت + زمان





کمترین مربعات: کرایه ≈ ۲٫۵ + ۲٫۱ × مایل + ۰٫۳ × دقیقه، و ۹۵٪ تغییرات توضیح داده می‌شود. با SQL: کرایه‌ی هر مایل در منهتن بیشترین است.

دام بزرگ: انعام نقدی ثبت نمی‌شود

۰

سفر نقدی با انعام ثبت‌شده

۹۰٪

سفرهای کارتی با انعام

۲۵٫۶٪

میانه‌ی انعام کارتی نسبت به کرایه

مسافران نقدی بی‌انعام نیستند؛ انعام نقدی به جیب راننده می‌رود و ثبت نمی‌شود. تحلیل انعام فقط روی سفرهای کارتی، و این محدودیت صریحاً در گزارش.

زرد یا سبز؟ مراقب منطقه باشید

منطقه	رنگ	تعداد	میانه‌ی درصد انعام
همه	زرد	3984	26.3
همه	سبز	565	11.8
منهتن	زرد	3678	26.7
منهتن	سبز	155	22.3
بروکلین	سبز	212	0.0

اختلاف کلی حدود ۱۴ واحد است و از نظر آماری معنی‌دار (t، من-ویتنی و بوت‌استرپ)، اما داخل منهتن به حدود ۴ واحد می‌رسد. مطالعه مشاهده‌ای است؛ ادعای علّی نمی‌کنیم.

گزارش نهایی: محدودیت‌ها و پیشنهاد

۱ **انعام نقدی ثبت نمی‌شود** نتایج انعام فقط برای پرداخت کارتی

۲ **فقط یک ماه** فصل و سال‌های دیگر ممکن است متفاوت باشند

۳ **نمونه‌ی کوچک** بخش کوچکی از کل سفرها

۴ **مشاهده‌ای** ادعای علّی نمی‌کنیم

۵ **قدم بعد** آزمون A/B روی دکمه‌های پیشنهادی صفحه‌ی پرداخت

پروژه‌ی پایانی شما: معیار ارزیابی

بخش	سهم
کیفیت سؤال‌ها و ارتباط تحلیل با آن‌ها	۱۵٪
پاک‌سازی و مستندسازی	۲۰٪
تحلیل اکتشافی و کیفیت نمودارها	۲۰٪
SQL (حداقل دو پرسش، شامل JOIN یا تابع پنجره‌ای)	۱۰٪
استدلال آماری درست، بدون ادعای علّی بی‌پشتوانه	۲۰٪
گزارش یک‌صفحه‌ای و ارائه‌ی ۱۰ دقیقه‌ای	۱۵٪

پایان ترم دوم

۱ NumPy و Pandas: آماده‌سازی و خلاصه‌سازی داده

۲ Matplotlib و Seaborn: نمودار صادق و خوانا

۳ SQL: کار با داده‌ی سازمانی

۴ احتمال و آمار: نتیجه‌گیری با عدم قطعیت

۵ جبر خطی: زبان مدل‌های ترم بعد

۶ ترم سوم: یادگیری ماشین